

Intelligent Modeling for Streamflow Forecasting

B. O. Brito, R. M. Salgado and L. A. Beijo

Abstract— In Brazil, electrical power generation stems mostly from hydroelectric power plants and this is due to the available geographical conditions. For optimization purposes and economy of these resources, streamflows forecasting is an alternative that helps in the planning of operations in hydroelectric power plants. It is proposed in this paper build models that are able to combine several forecasters, in order to get forecasts with minor errors and therefore more accurate. For this work, we used a base National Systems Operator data (ONS) of some plants that make up the Grande River. The strategy of combining forecasts obtained through different models show excellent results being a promising technique for streamflow forecasting.

Keywords— StreamFlow Forecasting, Power System Planning, Neural Networks, Genetic Programming, Ensemble.

I. INTRODUÇÃO

DENTRE as diversas fontes de geração de energia: hídrica, biomassa, eólica, fóssil, nuclear e solar, a hídrica é a mais explorada no Brasil, já que o território brasileiro é cortado por rios estáveis e abundantes e é, segundo [1], responsável atualmente por aproximadamente 62% da matriz energética brasileira, com um total de 1180 usinas em todo o país. Apesar de existirem outras fontes de energia, é sabido que estas nem sempre são baratas e podem ser altamente poluidoras.

Nos últimos anos, o Brasil enfrentou um período de escassez de água devido à estiagem e isso vem trazendo consequências que podem se agravar ao longo do tempo. Com a diminuição dos recursos hídricos disponíveis, maior se torna a importância do gerenciamento e planejamento destes.

O potencial energético de uma usina hidrelétrica é medido através da quantidade de água existente em seu reservatório, portanto para o seu planejamento de operação, essa informação é essencial para que se possa prever a quantidade máxima de energia que pode ser gerada.

Devido à complexidade dos fenômenos hídricos que tem como consequência a aleatoriedade das séries de vazões, existe a necessidade de estabelecer modelos capazes de representar com nível de precisão satisfatório o comportamento da vazão, a fim de reduzir a incerteza e os fatores que prejudicam o planejamento das operações de uma usina. A previsão de séries de vazões deve ser vista como parte integrante de um processo de tomada de decisões visando objetivos específicos, podendo minimizar prejuízos, diminuir custos e consequentemente melhorar o desempenho

de empresas geradoras de energia elétrica.

O processo de previsão pode se tornar difícil devido ao comportamento das séries de vazões, que apresentam uma natureza sazonal devido aos períodos intercalados de seca e umidade ao longo do ano, dificultando assim, o planejamento das operações energéticas. Uma maneira de ajudar no processo de decisão e planejamento das operações é o desenvolvimento de estudos sobre a vazão disponível em determinado reservatório.

Existem na literatura diversos modelos que são utilizados para este fim, porém a conclusão sobre qual é o melhor método ainda é contraditória. Dentre estes, as Redes Neurais Artificiais (RNA) [2] [18], Programação Genética (PG) [3], Modelos de Box e Jenkins [4], Lógica Neuro-Fuzzy [5], entre outros.

A partir da década de 90, os modelos baseados em RNA começaram a ser utilizados para as tarefas de previsão obtendo sucesso entre pesquisadores. Estes modelos fazem parte de uma área denominada inteligência artificial e são baseados na capacidade de aprendizado do cérebro humano. Algumas vantagens das RNA são: aprendem a partir de exemplos e não necessitam de conhecimento a priori sobre a modelagem do sistema a ser previsto, além disso, após ter aprendido as características de determinado conjunto de dados, as RNA tem uma alta capacidade de generalização.

Entre os trabalhos na área é possível destacar a metodologia proposta por [6], a qual foi aplicada para realizar previsão das vazões da bacia do Rio São Francisco seguindo um horizonte diário e semanal. Foram utilizadas redes neurais artificiais dos tipos *Multilayer Perceptron* (MLP) e *composite nonlinear sigmoidal regression blocks networks* (NSRBN). Dados de estações pluviométricas, fluviométricas e de vazão natural do reservatório de Três Marias, do período de janeiro/1987 a dezembro/2004 foram empregadas. Os erros obtidos foram em média de 16,9% e 17,1% para as redes MLP e NSRBN respectivamente, considerando o horizonte de previsão diário, que é inferior em comparação com os erros obtidos por outros sistemas como Cemig e PrevivazH que mostram um erro de 18,8% e 41,4%.

Foi proposto por [7], a comparação do modelo *wavelet* conjunto, que é a combinação entre os modelos *wavelet* e RNA. A série era diária e os dados eram da região Thrace, na Turquia. Os resultados do modelo sugerido aumentaram significativamente a precisão das previsões quando comparados ao modelo neural individual, o erro médio absoluto reduziu em 31% em relação a RNA.

RNA foi usada por [8] para fazer previsão de vazões diárias e por hora. Os dados utilizados foram da bacia do rio Winooski, localizada no noroeste de Vermont no EUA. O método mostrou bom desempenho com erros em torno de 20%.

Para estimar a vazão de afluência ao reservatório de Furnas

B. O. Brito, Universidade Federal de Alfenas (UNIFAL-MG), Alfenas, Minas Gerais, Brasil, brito.bethania@gmail.com

L. A. Beijo, Universidade Federal de Alfenas (UNIFAL-MG), Alfenas, Minas Gerais, Brasil, luiz.beijo@unifal-mg.edu.br

R. M. Salgado, Universidade Federal de Alfenas (UNIFAL-MG), Alfenas, Minas Gerais, Brasil, ricardo@bcc.unifal-mg.edu.br

(Minas Gerais, Brasil) com base em previsões quantitativas de chuvas do modelo regional ETA, [9] fizeram uso de RNA. As previsões das vazões realizadas possuem um horizonte de doze dias com intervalo diário. Os resultados levam à conclusão de que considerar as previsões das chuvas melhoram as previsões da vazão, com erros próximos a 11% e 13%.

RNA do tipo MLP foram empregadas por [10] para fazer previsão um passo a frente e n passos, os dados se referem a quatro usinas do Rio Grande sendo elas: Camargos, Itutinga, Funil Grande e Furnas. Os erros obtidos foram em torno de 19%.

Assim como as redes neurais artificiais, a programação genética é uma área da inteligência artificial que vem ganhando espaço como meio de fazer previsões para séries de vazões. Essa metodologia é baseada na seleção natural de Darwin [11] e foi desenvolvida por Koza [3].

Como destaque na área pode ser citado o trabalho de [12] no qual a técnica supracitada é utilizada para fazer previsão de séries de vazões a longo prazo no rio Manwan. A série histórica utilizada é mensal e corresponde ao período de janeiro de 1953 a dezembro de 2003. O desempenho da previsão fazendo uso de PG foi comparado com as RNA, sendo que a PG apresentou um erro relativo médio 7,97% menor que a RNA.

Um estudo realizado por [19] faz previsão de vazões mensais para a usina de Furnas através de uma metodologia baseada em regras fuzzy adaptativas (A-FSM). Os erros de previsão foram em torno de 19%.

O número estudos de previsão de séries de vazões utilizando modelos de *support vector machines* (SVM) vem crescendo nos últimos anos. O trabalho de [23] comparou diversos modelos de previsão incluindo o SVM. Os melhores resultados foram obtidos através de três dos modelos testados: *adaptive neural-based fuzzy inference system* (ANFIS), *genetic programming* (GP) e SVM.

O trabalho [24] utiliza um modelo SVM para fazer previsão de vazões no rio Lan-Yang. O modelo proposto mostrou grande eficiência para prever fases de inundações seis horas a frente.

Na pesquisa [25] o desempenho do modelo de SVM é comparado ao dos modelos ARMA e RNA para fazer previsão de vazões no rio Manwan Hydropower Schem. O modelo proposto é um candidato potencial para a predição deste tipo de série a longo prazo.

Uma técnica que pode ser bastante útil no ramo de previsão e que vem sendo utilizada são os *ensembles*, que consiste em combinar previsões através de uma equação ou modelo. Um exemplo pode ser visto em [13], onde foram utilizados modelos inteligentes para fazer previsão de carga e em seguida as previsões obtidas desses modelos foram combinadas através de três combinadores: média aritmética, média ponderada e um modelo não-linear baseado em RNA. Os resultados deste estudo mostraram que através de *ensembles* é possível obter resultados mais precisos do que quando são consideradas as componentes individuais, reduzindo os erros em torno de 0,15%, 0,99% e 0,2%.

Ensemble foi empregado também por [14] no mesmo

contexto de previsão de energia. As componentes individuais foram as RNA e SVM. Após obtidas as componentes individuais, estas foram combinadas através da própria RNA. O erro de previsão obtido pelo combinador foi de 25%, menor que a melhor componente individual.

Uma metodologia para combinar modelos de previsão para prever a vazão do rio Guadalupe, na Colômbia foi utilizado por [20]. Foram combinados quatro tipos de modelos: modelos autoregressivos (AR), modelos autoregressivos itegrados de médias móveis (ARIMA), redes neurais artificiais, análise do espectro singular. Os combinadores testados foram: média aritmética, média ponderada, redes neurais e ANFIS, estes foram testados para horizontes de um, três e seis meses. A melhor estratégia de combinação foi o ANFIS com erro de aproximadamente 8%.

Através da revisão de literatura foi possível perceber que a previsão de séries de vazões pode ser abordada de diversas maneiras. Neste trabalho, o foco está em realizar previsões através de RNAs e programação genética abordando a metodologia de *ensembles*, que ainda é pouco explorada na literatura.

Diante dessa óptica, este trabalho propôs realizar previsões de vazões através de *ensembles* e comparar o desempenho destes com o das componentes individuais de previsão, afim de verificar se houve melhora ao combiná-las. As previsões foram realizadas para os períodos seco e úmido separadamente e os dados utilizados para realização dos experimentos são da ONS (Operador Nacional do Sistema Elétrico) e correspondem a algumas usinas da Bacia do Rio Grande.

II. FUNDAMENTAÇÃO TEÓRICA

Para a realização das previsões de séries de vazões, faz-se necessário o uso de modelos que serão apresentados brevemente a seguir.

Redes Neurais Artificiais

Redes Neurais Artificiais são sistemas de processamento de informação não-linear baseado na estrutura do neurônio biológico. Suas principais características são a capacidade de auto-organização, auto-adaptação e aprendizagem em tempo real. Logo, as Redes Neurais Artificiais emulam a capacidade de aprendizagem humana [22].

O processo de aprendizado das redes neurais artificiais é implementado com base em exemplos, também chamado de treinamento da rede, esta fase consiste em ajustar pesos com o objetivo de minimizar o erro e obter resultados o mais próximo possível da realidade.

A arquitetura de uma rede pode se dar de diferentes disposições, tais como o número de camadas ocultas e de neurônios, a forma como os neurônios estão conectados, a função de transferência e etc. Um tipo de arquitetura de RNA utilizada é o *Perceptron* de Múltiplas Camadas (*Multilayer Perceptron*) ou MLP.

Como pode ser visto na Fig. 1, esse tipo de arquitetura é composta por uma camada de entrada, onde os padrões são apresentados à rede e propagados para a camada seguinte.

Uma ou mais camadas intermediárias, onde o processamento é efetuado e onde se transmite as informações por meio de conexões entre as unidades de entrada e saída. E a camada de saída, composta por neurônios que recebem as informações das camadas ocultas fornecendo a resposta.




Figura 1. Estrutura de uma RNA do tipo MLP com duas camadas intermediárias.

Programação Genética

A PG foi desenvolvida por [3], esta técnica é baseada na teoria de Darwin onde os indivíduos que mais se adaptam ao meio sobrevivem [11].

Na PG os indivíduos são programas formados pela combinação do conjunto de funções (operadores) e terminais (variáveis e constantes) adequados ao domínio do problema, aos quais são associados um valor de mérito *fitness*, representando o quanto ele é capaz de resolver o problema. O objetivo é encontrar uma solução no espaço de todos os programas possíveis. A representação de cada programa é feita através de uma árvore de sintaxe abstrata. Por exemplo, um indivíduo $x^2 + 2$ pode ser representado como na Fig. 2.




Figura 2. Representação do programa $x^2 + 2$.

A PG pode ser descrita como um processo em que os programas são criados baseados no conhecimento do domínio do problema. Em seguida, são testados para verificar sua

funcionalidade, se os resultados não forem satisfatórios, modificações são feitas para melhorá-los.

A Fig. 3 ilustra uma visão geral do algoritmo de PG. Pode-se observar como é possível chegar em uma solução aceitável para o problema.

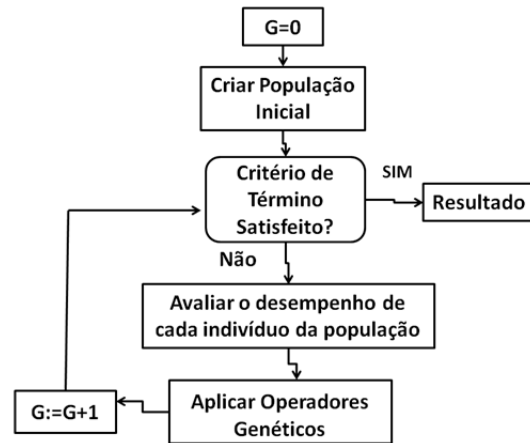


Figura 3. Algoritmo da Programação Genética.

O ciclo representado pela Fig. 3 se repete até que um critério de término seja atingido. Este critério de término pode ser determinado por um número máximo de gerações ou até que uma solução satisfatória seja encontrada.

III. METODOLOGIA

Neste trabalho foram realizadas previsões de vazões para algumas das usinas hidroelétricas do Rio Grande, que nasce no estado de Minas Gerais e banha também o estado de São Paulo. As previsões foram realizadas para: Camargos, Funil Grande, Furnas, Mascarenhas de Moraes, Jaguará, Igarapava, Volta Grande, Porto Colômbia, Marimbondo, Caconde, Eduardo da Cunha e A. S. Oliveira.

Os modelos empregados para a realização das previsões foram as RNAs MLP com sete diferentes algoritmos de treinamento [21], sendo dois de primeira ordem: *Backpropagation* (BPM) e *Gradient Method* (GRAD), e cinco de segunda ordem: *Davidon Fletcher Powell quasi Newton* (DFP), *Broyden Fletcher Goldfarb Shanno quasi Newton* (BFGS), *Non quadratic problems Polak Ribière method* (PR), *Fletcher & Reeves Method* (FR), *Scaled Conjugate Gradient method* (SCGM). Além da RNA, foi utilizado outro algoritmo bioinspirado: a PG [3].

A base de dados analisada neste trabalho foi dividida em três partes: 62 anos (1931-1993) para o treinamento do modelo, 10 anos (1994-2003) para validação e 10 anos (2004-2013) de teste. A previsão utilizada foi do tipo um passo a frente, que faz uso de dados do histórico para fazer previsão de valores futuros.

Um parâmetro importante para se realizar previsões é o número de atrasos, neste trabalho foram utilizados pelo modelo meses imediatamente anteriores ao mês a ser previsto, que correspondem aos meses que devem ser levados em consideração para modelar a dependência. Para determinação do número de atrasos utilizou-se a função de auto-correlação amostral (FAC) (Equação 1). Para exemplificar o número de

atrasos tem-se a TABELA I, onde m representa o mês a ser previsto.

$$r_k = \frac{\sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2} \quad (1)$$

TABELA I
EXEMPLO DE PADRÃO UTILIZADO PELOS MODELOS

Entradas			Saídas
m-n	...	m-2 m-1	m

Nos modelos de RNA, após a preparação do banco de dados, para um melhor desempenho dos algoritmos foi realizada uma busca dos parâmetros, ou seja, quais as configurações do modelo com o qual seria possível obter um menor erro de previsão da série. O intervalo de busca dos parâmetros está na TABELA II.

TABELA II
INTERVALO DE BUSCA DOS PARÂMETROS

Número de Neurônios	[3;15]
Taxa de Aprendizagem	[0;1]
Termo <i>Momentum</i>	[0;1]

Assim como nas RNA, a PG possui parâmetros que podem ser alterados para realização do treinamento do modelo. Os valores destes parâmetros utilizados estão descritos na TABELA III.

TABELA III
VALORES DOS PARÂMETROS PARA A PROGRAMAÇÃO GENÉTICA

Tamanho da População	100
Número de Gerações	50
Operadores Genéticos	{+, -, *, sem, cos, log}

A Fig. 4 mostra os procedimentos para a obtenção dos resultados. Os experimentos foram realizados a fim de obter quais os parâmetros que resultavam em menores erros de previsão, após obter a configuração da melhor combinação de parâmetros, os experimentos foram realizados com os parâmetros já definidos. Como critério de avaliação, foi adotado o menor erro relativo médio (ERM) obtido no padrão de validação. A escolha destes resultados permite definir qual é o intervalo em que estão os parâmetros adaptados ao problema.

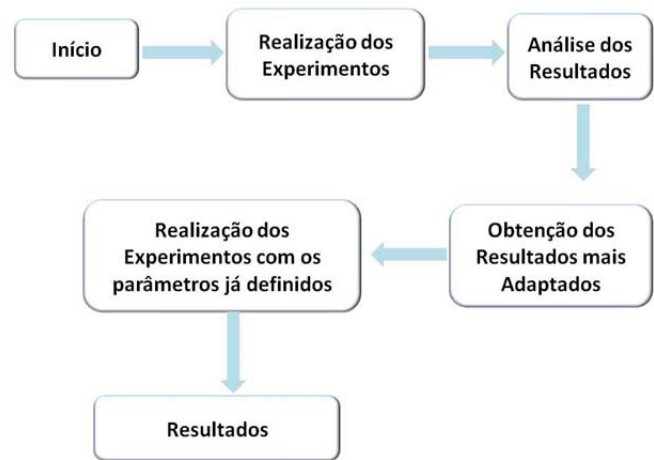


Figura 4. Obtenção dos Resultados para Componentes Individuais.

Após o ajuste dos modelos inteligentes foi utilizado um combinador. As previsões obtidas através dos modelos RNA e PG ($x_1, x_2, x_3, \dots, x_n$) foram combinados a fim de obter melhores estimativas, ou seja, com menor erro e maior estabilidade. Um esquema de combinadores pode ser visto na Fig. 5.

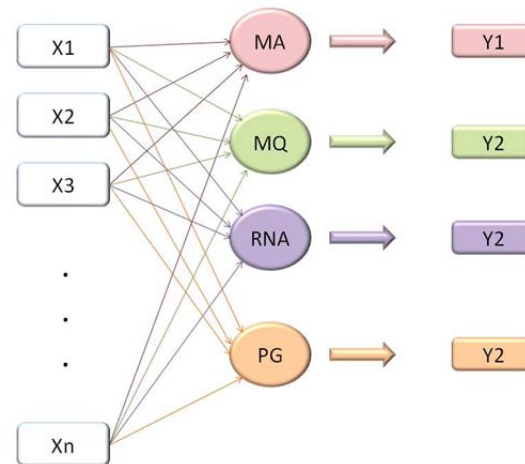


Figura 5. Esquema do *Ensemble*.

O *ensemble* consiste em combinar as previsões distintas obtidas pelos modelos individuais a fim de obter um único predictor. Foram utilizados diferentes tipos de combinador: Média Aritmética (MA), Média Quadrática (MQ), Redes Neurais Artificiais (RNA) e Programação Genética (PG) como esquematizado em Fig. 5.

As médias estão descritas na TABELA IV, no qual x_1, x_2, \dots, x_n são as previsões das n componentes individuais e n é o total de componentes a serem combinadas. O funcionamento dos modelos inteligentes como combinadores serão descritos posteriormente.

TABELA IV
ENSEMBLES

Médias Utilizadas	Descrição
Média Aritmética	$MA = \frac{X_1 + X_2 + \dots + X_n}{n}$
Média Quadrática	$MQ = \sqrt{\frac{x_1^2 + x_2^2 + \dots + x_n^2}{n}}$

Outros combinadores que foram desenvolvidos neste trabalho são as RNA do tipo MLP e a PG, ou seja, as componentes geradas anteriormente foram combinadas através de uma RNA e uma PG para gerar uma única saída.

Para a construção de um combinador empregando RNA e PG, seguiu-se três etapas. Divide-se o conjunto de dados em três partes, correspondente ao período de treino, validação e teste. Em seguida realiza-se a previsão do conjunto de validação utilizando as componentes a serem combinadas. E por fim constrói-se o combinador propriamente dito. Nesta última etapa, as previsões da validação obtidas pelas componentes individuais são empregadas como o conjunto de treinamento do combinador. Desta forma, o modelo é capaz de ponderar as componentes de forma que, aqueles modelos que mostraram um desempenho melhor recebam um peso maior, permitindo obter as previsões para o período de teste.

Como objetivo de reduzir os erros de previsão devido a diferença de variabilidade existente nos períodos de chuva e estiagem, os resultados foram divididos em duas partes: período úmido, correspondente aos meses de novembro a abril e período seco, que se refere aos meses de maio a outubro.

O desempenho dos modelos testados foi comparado através do erro de previsão de cada um, calculados através da Equação 2 (Erro Relativo Médio),

$$ERM = \frac{1}{n} \sum_{i=1}^n \left| \frac{x_i - \hat{x}_i}{x_i} \right| * 100 \quad (2)$$

no qual x_i é o valor observado e \hat{x}_i é o valor previsto.

IV. APRESENTAÇÃO DOS DADOS

Os dados utilizados neste trabalho são do Operador Nacional do Sistema Elétrico (ONS) e correspondem ao período de 1931 a 2013 e representam a vazão média mensal de algumas usinas do Rio Grande. Para o melhor entendimento da variável estudada são apresentadas na TABELA V, algumas medidas descritivas.

TABELA V
MEDIDAS DESCRITIVAS DA VAZÃO ($m^3 s^{-1}$) PARA OS PERÍODOS SECO E ÚMIDO

Período Seco					
Usina	Máx.	Mín.	Média	Desv. Pad.	Coef. Var. (%)
ASOliveira	196	12	53,04	21,94	41,37
E. Cunha	192	12	52,21	21,62	41,41
F. Grande	666	68	177,13	66,03	37,28
Igarapava	2605	229	637,69	267,13	41,89
Jaguara	2537	227	620,18	259,32	41,81
V. Grande	2753	235	677,02	284,38	42,00
P. Colômbia	3091	245	769,17	325,71	42,35
Caconde	113	8	31,86	13,26	41,62
Camargos	332	34	79,50	31,81	40,00
Furnas	2303	204	536,67	227,76	42,44
Marimbondo	4405	418	1124,79	458,57	40,77
M. Moraes	2455	225	599,14	250,12	41,75
Período Úmido					
Usina	Máx.	Mín.	Média	Desv. Pad.	Coef. Var. (%)
ASOliveira	408	24	125,51	64,21	51,16
E. Cunha	402	24	123,62	63,30	51,20
F. Grande	1288	112	432,85	203,29	46,97
Igarapava	4429	351	1559,52	751,04	48,16
Jaguara	4334	342	1517,60	730,52	48,14
V. Grande	4654	371	1652,63	796,73	48,21
P. Colômbia	5228	420	1877,52	908,40	48,38
Caconde	235	12	75,93	37,87	49,88
Camargos	576	48	186,56	87,32	46,80
Furnas	3757	295	1313,64	633,30	48,21
Marimbondo	7228	592	2586,55	1210,9	46,82
M. Moraes	4220	331	1468,00	706,86	48,15

A TABELA V mostra o máximo, o mínimo, a média, desvio padrão e o coeficiente de variação das séries de vazões das usinas estudadas para os períodos seco e úmido. Na parte superior da tabela encontram-se as usinas a fio d'água e na parte inferior as usinas de reservatório. Como é possível perceber na tabela, o coeficiente de variação apresentado é alto, indicando alta variabilidade dos dados em relação à média, o que dificulta a previsão das séries de vazões. Além disso, é possível perceber que nos períodos úmidos a média e o desvio padrão são maiores que no período seco, tal fato foi constatado também por [10], que mostram em seu estudo que além da média, há uma diferença no desvio padrão ao longo dos meses, sendo maior nos meses chuvosos, este fato pode ser observado também na Fig. 6.

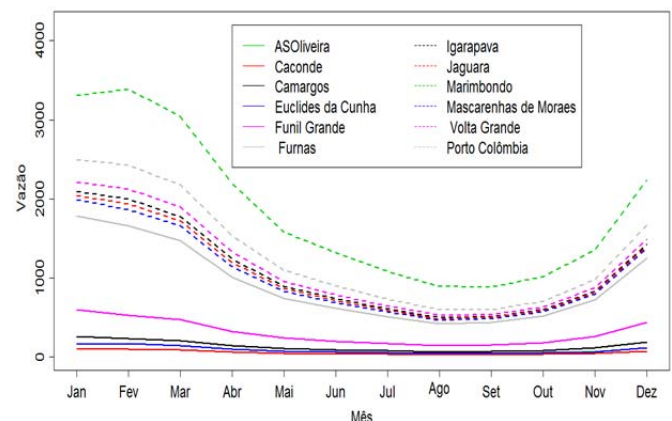


Figura 6. Comportamento da vazão mensal (m^3/s) das usinas do Rio Grande de 1931 a 2013 (Média de Longo Termo).

Através da Fig. 6, pode-se observar um fator relevante, nos meses de cheia (novembro a abril) há uma diferença significativa nos valores médios em relação aos meses de seca (maio a outubro), tal fato é constatado também nos trabalhos de [16], [10] e [17] que fizeram estudos de séries de vazões de forma semelhante a este trabalho. Este fator pode ser melhor visualizado através das Fig. 7.

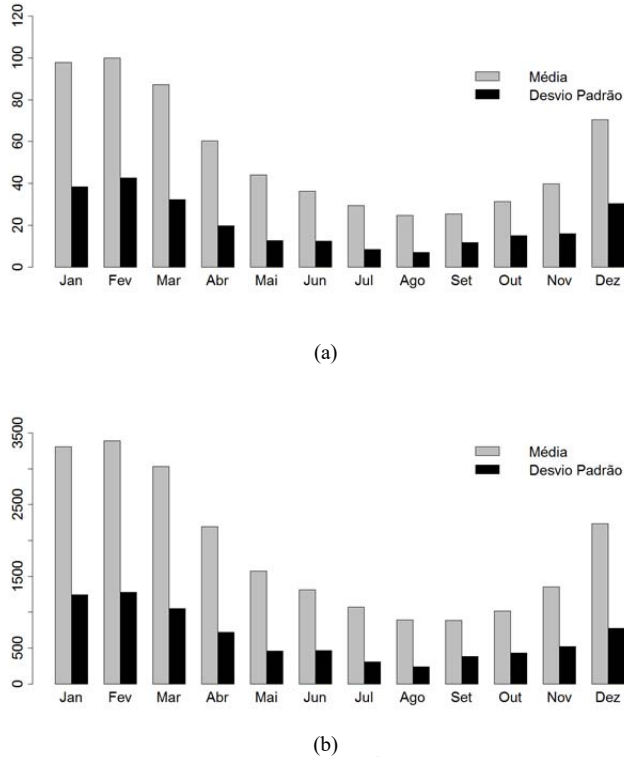


Figura 7. Média e desvio padrão da vazão (m^3/s) das usinas Caconde (a) e Marimondo (b).

A Fig. 7 apresenta a média e o desvio padrão para as usinas de menor (Caconde) e maior (Marimondo) médias de vazão. A média geral da vazão para a usina de Caconde é de $31,86 \text{ m}^3/\text{s}$ e $75,93 \text{ m}^3/\text{s}$ para os períodos seco e úmido respectivamente. O desvio padrão para os mesmos períodos foram de $13,26 \text{ m}^3/\text{s}$ e $37,87 \text{ m}^3/\text{s}$.

A média da vazão para a usina de Marimondo para os períodos seco e úmido são respectivamente de $1124,79 \text{ m}^3/\text{s}$ e $2586,55 \text{ m}^3/\text{s}$, com desvio padrão de $458,57 \text{ m}^3/\text{s}$ e $1210,91 \text{ m}^3/\text{s}$.

V. ESTUDOS DE CASOS

Os estudos de casos apresentados neste trabalho se referem a previsão de séries de vazões das seguintes usinas hidroelétricas do Rio Grande: Camargos, Funil Grande, Furnas, Mascarenhas de Moraes, Jaguará, Igarapava, Volta Grande, Porto Colômbia, Marimondo, Caconde, Euclides da Cunha e A. S. Oliveira.

Os resultados serão apresentados através de tabelas para as componentes individuais e os *ensembles* em duas subseções, uma para o período seco e outra para o período úmido. Além disso, os resultados para as usinas a fio d'água e de reservatório serão apresentados em tabelas distintas. Será

apresentada também uma terceira subseção onde se encontram os resultados para os *ensembles* Média Aritmética (MA) e Média Quadrática (MQ).

Resultados para o período seco

Na TABELA VI encontram-se os resultados para as usinas a fio d'água considerando o período seco. Para as componentes individuais o modelo que apresentou melhores resultados para estas usinas foi o GRAD, com ERM entre 8,15% e 13,72%, exceto para a usina A. S. Oliveira cujo melhor modelo foi o BPM com ERM de 13,54%.

TABELA VI
ERM (%) PARA AS PREVISÕES DAS USINAS A FIO D'ÁGUA DO PERÍODO SECO

ASOliveira								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	13,6	13,5	14,51	13,6	13,7	14,2	13,6	13,9
Comb.	13,5	13,7	13,9	14,6	13,8	13,5	14,4	14,1
Euclides da Cunha								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	14,3	13,8	13,9	13,8	13,7	14,9	13,7	13,9
Comb.	13,9	13,7	15,4	26,4	17,0	14,3	13,7	14,4
Funil Grande								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	13,0	13,0	9,8	13,5	8,6	12,4	12,4	10,8
Comb.	9,1	8,9	9,8	8,2	13,5	9,9	21,2	13,1
Igarapava								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	15,2	13,4	11,6	13,8	9,5	14,3	14,0	13,0
Comb.	13,2	13,0	10,9	12,6	12,6	9,3	12,4	16,7
Jaguara								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	15,5	13,9	17,4	14,8	12,4	15,2	14,5	13,8
Comb.	9,1	8,6	12,1	10,3	25,6	9,0	12,6	14,1
Volta Grande								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	14,3	13,3	13,4	14,2	9,0	13,2	13,2	12,1
Comb.	9,9	8,5	9,2	9,0	10,4	8,7	12,5	12,9
Porto Colômbia								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	13,1	12,6	11,9	12,0	8,2	11,8	11,8	11,5
Comb.	10,3	8,1	11,6	13,4	13,5	8,1	11,2	13,1

• Modelo com o qual obteve-se menor erro de previsão.

A TABELA VII mostra os resultados para as usinas de reservatório para o período seco. Observando os resultados para as componentes individuais o modelo que mais se destacou foi a RNA com algoritmo de treinamento GRAD, apresentando ERM entre 7,93% e 11,25%, exceto para a usina de Caconde, cujo modelo de destaque foi o FR com ERM de 14,23%. Já para os *ensembles*, neste mesmo período, para a usina de Camargos não houve nenhum combinador que mostrou desempenho superior ao da melhor componente individual (GRAD com ERM=7,93%), apesar de alguns deles terem resultados bem próximos destas, como por exemplo, o algoritmo PR que apresentou ERM de 8,28%. Para as usinas de Caconde, Furnas, Mascarenhas de Moraes e Marimondo os modelos que tiveram melhores resultados foram BPM (14,18%), PR (9,04%), BPM (8,59%) e FR (9,63%), respectivamente.

TABELA VII
ERM (%) PARA AS PREVISÕES DAS USINAS DE RESERVATÓRIO DO
PERÍODO SECO

Caconde								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	14,9	14,6	14,5	14,2	16,6	16,7	14,8	15,0
Comb.	15,3	14,1	16,9	16,6	26,1	14,3	14,6	14,3
Camargos								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	13,31	10,9	9,9	12,7	7,9	11,6	10,9	13,0
Comb.	16,8	8,7	10,7	9,6	14,8	8,30	18,0	9,4
Furnas								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	15,4	15,4	16,3	15,1	11,3	15,8	14,9	14,7
Comb.	11,4	9,6	10,8	9,9	13,3	9,0	9,9	12,9
Marimbondo								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	14,7	12,8	14,0	13,7	10,3	12,8	11,4	11,4
Comb.	10,1	10,7	12,4	9,6	10,4	10,1	13,00	14,7
Mascarenhas de Moraes								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	13,8	14,7	17,6	15,1	10,4	14,8	14,7	13,5
Comb.	9,6	8,6	9,7	14,8	9,5	13,00	13,0	16,3

- Modelo com o qual obteve-se menor erro de previsão.

Para as componentes individuais, considerando o período seco, tanto para as usinas a fio d'água quanto para as de reservatório o melhor modelo foi a RNA com algoritmo de treinamento GRAD. Já para os *ensembles* não houve um único modelo que foi melhor na maioria dos casos, mas entre os analisados três deles se destacaram : BPM, FR e PR.

Resultados para o período úmido

Esta subseção aponta os resultados para o período úmido para as usinas a fio d'água e de reservatório, assim como na subseção anterior. A TABELA VIII mostra os resultados para as usinas a fio d'água para este período, as componentes individuais que se destacaram foram o BPM e GRAD e o ERM variou entre 13,26% e 23,95%.

TABELA VIII
ERM (%) PARA AS PREVISÕES DAS USINAS A FIO D'ÁGUA DO
PERÍODO ÚMIDO

ASOliveira								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	19,9	14,6	16,7	17,4	14,9	14,9	19,2	19,2
Comb.	14,9	13,7	17,6	17,9	15,5	21,5	47,9	18,1
Euclides da Cunha								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	17,7	13,3	20,4	17,0	14,1	13,6	23,1	21,9
Comb.	13,5	11,8	13,6	16,3	16,6	28,7	74,0	15,8
Funil Grande								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	27,9	24,6	30,4	24,1	23,9	25,5	35,8	24,2
Comb.	29,3	27,3	29,4	33,3	26,9	35,8	82,5	36,5
Igarapava								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	29,7	23,2	32,9	26,6	24,9	28,1	33,5	26,5
Comb.	25,4	22,9	29,1	26,7	22,9*	32,2	44,7	24,5
Jaguara								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	28,5	25,6	28,2	27,7	23,9	28,3	29,9	27,5
Comb.	31,2	23,8	28,9	29,3	25,8	32,8	99,6	30,4
Volta Grande								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	28,3	22,5	27,5	23,9	24,8	26,9	27,5	24,1
Comb.	22,0	21,3	24,9	22,7	23,5	22,6	40,6	21,8
Porto Colômbia								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp.	27,1	24,4	26,9	24,2	23,7	30,0	26,9	24,2
Comb.	20,2	21,5	19,1	20,2	20,4	19,6	139,5	19,9

- Modelo com o qual obteve-se menor erro de previsão.

Ao combinar os modelos em estudo na maioria dos casos o algoritmo BPM obteve sucesso, exceto para a usina Porto Colômbia cujo *ensemble* de destaque foi o DFP. É importante destacar também que, para a usina Funil Grande, apesar do melhor combinador ter sido o BPM, este não superou o desempenho da componente de menor ERM.

Observando os resultados para as componentes individuais das usinas de reservatório no período úmido, que se encontram na TABELA IX, o modelo que mais se destacou para as usinas de Camargos e Marimbondo foi o BPM com ERM de 25,38% e 20,87%, respectivamente. Para as usinas de Furnas e Mascarenhas de Moraes o melhor modelo foi o GRAD com ERM de 24,62% e 23,83%. Já para Caconde a componente de destaque foi o PR com ERM de 16,20%.

TABELA IV
ERM (%) PARA AS PREVISÕES DAS USINAS DE RESERVATÓRIO DO
PERÍODO ÚMIDO

Caconde								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp	19,1	17,8	18,1	25,8	17,8	16,2	18,8	17,6
Comb	19,9	17,1	17,9	16,7	20,2	23,8	111,8	18,0
Camargos								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp	35,9	25,4	32,9	28,7	25,9	27,6	38,1	25,6
Comb	22,3	25,9	23,1	23,5	25,9	29,5	62,6	25,4
Furnas								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp	30,5	25,9	35,8	29,3	24,6	26,8	34,8	27,7
Comb	25,0	22,8	30,7	26,7	24,0	31,6	50,6	25,6
Marimbondo								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp	22,5	20,9	22,9	21,4	21,5	21,7	22,5	24,4
Comb	29,5	19,3	26,0	27,6	20,6	20,7	50,4	23,6
Mascarenhas de Moraes								
	BFGS	BPM	DFP	FR	GRAD	PR	SCGM	PG
Comp	29,1	24,1	30,0	28,4	23,8	28,1	34,7	26,4
Comb	27,0	19,4	28,2	24,9	26,3	37,0	84,4	25,6

- Modelo com o qual obteve-se menor erro de previsão.

Analisando os resultados dos *ensembles*, o algoritmo BPM teve desempenho superior aos demais na maioria dos casos com ERM entre 19,30% e 22,77%, exceto para a usina de Camargos cujo combinador de destaque foi o BFGS (ERM=22,29%). Para Caconde, nenhum dos combinadores tiveram desempenho superior ao da melhor componente individual.

Como é possível perceber, para as componentes individuais no período em estudo os algoritmos de destaque foram o BPM e GRAD. Já para os *ensembles* o modelo BPM foi que obteve sucesso na maioria dos casos.

Resultados para os *ensembles* Média Aritmética (MA) e Média Quadrática(MQ)

Os resultados para os combinadores MA e MQ estão na TABELA X, na parte superior da tabela se encontram as usinas a fio d'água e na parte inferior as de reservatório. Os ERM em destaque na tabela indicam os combinadores, MA ou MQ, com os quais foi possível obter um desempenho superior aos combinadores RNA ou PG. Como é possível perceber, tal fato ocorre em poucos casos e apenas para o período seco.

TABELA X
ERM(%) DAS PREVISÕES OBTIDAS ATRAVÉS DOS *ENSEMBLES* MA
E MQ

Usinas	Período Seco		Período Úmido	
	MA	MQ	MA	MQ
ASOliveira	12,38	12,36	21,76	23,48
Euclides da Cunha	12,76	12,78	21,68	21,99
Funil Grande	9,65	9,72	24,80	25,41
Igarapava	14,34	14,48	25,95	26,10
Jaguara	14,19	14,30	25,03	25,15
Volta Grande	14,70	14,83	25,18	25,77
Porto Colômbia	14,39	14,56	25,64	25,82
Caconde	13,20	13,19	22,23	22,83
Camargos	9,19	9,25	25,53	26,66
Furnas	14,86	14,94	26,73	26,85
Marimbondo	14,53	14,67	22,05	22,57
M. Moraes	14,79	14,91	25,74	25,94

Discussão dos Resultados

Observando os resultados de uma maneira geral, pode-se verificar que fazer previsões de vazões utilizando *ensembles* contribuiu para a obtenção de resultados mais precisos. Essa evidência foi apresentada também no trabalho [14]. O modelo que forneceu melhores resultados foi a RNA com algoritmo de treinamento BPM.

Ao comparar os *ensembles* RNA e PG com as médias verifica-se que na maioria dos casos as RNA's tiveram desempenho superiores para ambos os períodos. Através das médias foi possível obter resultados melhores que os das componentes individuais, ou seja erros de previsão menores que nas componentes. Porém, o desempenho dos combinadores inteligentes ainda são superiores, pois estes modelos são capazes de atribuir pesos as componentes de previsão de forma mais uniforme que os demais combinadores. Além disso, sabe-se que as médias são influenciadas por valores extremos, logo se algum modelo errou muito ao prever, isso vai influenciar também no desempenho destes combinadores.

Comparando os resultados das previsões dos períodos secos e úmidos é possível perceber como os erros do período úmido são maiores. Este fato está relacionado com a variação sazonal da série que é influenciada pela diferença na variabilidade e nas demais medidas de posição apresentadas na Seção IV que são maiores para o período úmido resultando em erros de previsão superiores para este período.

Apesar de na literatura os trabalhos não analisarem os erros de previsão para os períodos separadamente, os valores encontrados neste trabalho são compatíveis, em média, com os da literatura [10], [6], [14], [19], sendo em média de 20%.

As simulações realizadas neste artigo foram realizadas em um computador equipado com processador Intel core i5 (2.7 Ghz) com 4 Gb de memória RAM executando o sistema operacional Microsoft Windows 8. Os scripts desenvolvidos foram executados utilizando o software MATLAB. Em média para executar o treinamento e a previsão das componentes individuais foram necessários entre 30 a 60 minutos. Após o processo de treino das componentes individuais os combinadores alcançavam os resultados de previsão em poucos segundos.

IV. CONCLUSÕES

É importante destacar que não houve um modelo que teve o melhor desempenho em todos os casos quanto aos erros de previsão, os resultados dependem das usinas e também do período em estudo.

De modo geral, o ERM da previsão do período seco é menor que no período úmido, isso se deve ao fato de esse período apresentar menor variabilidade, como pode ser visto na análise descritiva dos dados, possibilitando maiores acertos.

Através das análises realizadas foi possível observar que as redes neurais artificiais do tipo MLP e a programação genética são modelos promissores para realizar previsões. Os algoritmos de treinamento mostraram bom desempenho, sendo que os erros de previsão são aceitáveis para o tipo de dado trabalhado, muitas vezes sendo inferiores a outras metodologias utilizadas na literatura.

Pode-se dizer que na maioria dos casos, as componentes mais promissoras foram o GRAD e BPM, tanto para o período seco como para o úmido, para as usinas a fio d'água e de reservatório.

A estratégia de combinar previsões obtidas através de diferentes modelos possibilitou, na maioria das vezes, a diminuição do ERM, mostrando ser uma técnica promissora para previsão de séries de vazões. Pode-se destacar o modelo BPM testado como *ensembles*. O ERM obtido foi de até 9,03% e 15,76% menor que as componentes individuais para os períodos seco e úmido, respectivamente.

REFERÊNCIAS

- [1] Agência Nacional de Energia Elétrica, ANEEL. "Matriz de energia elétrica", 2015. Disponível em <http://www.aneel.gov.br/>. Acessado em 19-set-2015.
- [2] S. Haykin, 2007. "Redes Neurais: Princípios e Práticas", Editora Bookman, 2 ed.
- [3] J. R. Koza, 1992. "Genetic Programming: On the Programming of Computers by Means of Natural Selection". Cambridge, USA. MIT Press.
- [4] G. E. P. Box, and Jenkins, G. M., 1976. "Time Series Analysis: Forecasting and Control". California, USA. San Francisco: Holden Day, 2nd. ed.
- [5] J. S. R. Jang, "ANFIS: Adaptive Network Based Fuzzy Inference System". IEEE Transaction System, Man and Cybernetics, 2003.
- [6] L. F. C. Gomes, S.M.G.L. Montenegro, "Modelo baseado na técnica de redes neurais para previsão de vazões na bacia do rio São Francisco". Revista Brasileira de Recursos Hídricos, v.15, n.1, p.05-15, 2010.
- [7] O. Kisi, "Neural Networks and Wavelet Conjunction Model for Intermittent Streamflow Forecasting". Journal of Hydrologic Engineering, v.14, p.773-782, 2009.
- [8] L. E. Besaw, D. M. Rizzo, P. R. Bierman, "Advances in ungauged streamflow prediction using artificial neural network". Journal of Hydrology, v.386, p.27-37, 2010.
- [9] J. M. Bravo, O. C. Pedrollo, W. Collischonn, A. R. Paz, C. B. Uvo, "Previsões de curto prazo de vazão afluente ao reservatório de Furnas utilizando redes neurais artificiais". Revista Brasileira de Recursos Hídricos, v.13, n.2, p.77-88, 2008.
- [10] D. B. Lima, M. D. C. E. Lima, R. M. Salgado, "An Empirical Analysis of MLP Neural Networks Applied to Streamflow Forecasting". IEEE International Conference on Intelligent Computing and Intelligent Systems, v.9, n.3, p. 295-301, 2011.
- [11] C. Darwin, "On the Origin of Species by Means for Natural Selection". London: Jhon Murray, 1859.
- [12] W. Wang, D. Xu, L. Qiu, J. Ma, "Genetic programming for modelling long term hydrological time series". IEE-Fifth International Conference on Natural Computation, 2009.
- [13] M. O. Moreira, R. M. Salgado, T. Ohishi, E. B. Ferreira, "Modelo Baseado em Combinação de Previsores para Previsão de Séries Temporais de Carga Elétrica". Revista GEINTEC. São Cristóvão/SE, v.1, n. 2, p. 20-31, 2011.

- [14] R. M. Salgado, J. J. F. Pereira, T. Ohishi, R. Ballini, C. A. M. Lima, F. J. Von Zuben, "A Hybrid Ensemble Model Applied to the Short-Term Load Forecasting Problem". In: International Joint Conference on Neural Networks, 2006. p.16-21, Vancouver, Canadá.
- [15] Operador Nacional do Sistema - ONS. "Séries de Vazões Mensais", 2015. Disponível em <http://www.ons.org.br/download/> Acessado em 29-jul-2015.
- [16] R. Balline, M. G. Andrade, S. Soares, "Previsão Médias Mensais Usando Redes Neurais Nebulosas". Revista Controle & Automação, v.14, n.3, 2003.
- [17] R. M. Salgado, I. Luna, R. Ballini, S. Soares, D. Silva Filho, "Modelos de Inteligência Computacional para Geração de Séries Sintéticas de Vazões Médias Mensais". Learning and Nonlinear Models, v.10, n.3, p.166-174, 2012.
- [18] D. S. Ramos, T. E. D. C. Huayllas, "Electric Power Forecasting Methodologies of Some South American Countries: A Comparative Analysis", IEEE LATIN AMERICA TRANSACTIONS, Vol. 8, No. 5, pp. 519-525, Sept. 2010.
- [19] I. H. Luna, R. Ballini, S. Soares, "An Adaptive Hybrid Model for Monthly Streamflow Forecasting". In: The IEEE International Conference on Fuzzy Systems - FUZZ-IEEE'07, Proceedings of the IEEE International Conference on Fuzzy Systems, . p. 1-6., London, 2007.
- [20] J. D. Rojo, L. F. Carvajal, J. D. Velásquez, "Streamflow Prediction using a Forecast Combining System". IEEE LATIN AMERICA TRANSACTIONS, v.13, n.4, 2015.
- [21] R. Battiti, "First-and-Second Order Methods for Learning: Between Steepest Descent and Newton's Method". Neural Computation, v. 4, p. 141-166, 1992.
- [22] S. Ding, H. Li, C. Su, J. Yu, F. Jin, "Evolutionary artificial neural networks: a review". Artif Intell Rev, v.39, p.251-260, 2013.
- [23] W. Wang, K. Chau, C. Cheng, L. Qiu, "A comparison of performance of several artificial intelligence methods for forecasting monthly discharge time series". Journal of Hydrology, v. 374, p. 294 – 306, 2009.
- [24] P. Yu, S. Chen, I. Chang, "Support vector regression for real-time flood stage forecasting". Elsevier, v. 328, p. 704 – 716, 2006.
- [25] J. Lin, C. Cheng, K. Chau, "Using support vector machines for long-term discharge prediction". Taylor & Francis, v. 51, p. 599 – 612, 2006.



Bethânia Oliveira de Brito, é bacharel em Ciências Exatas e Estatística pela Universidade Federal de Juiz de Fora. Atualmente é mestranda na Universidade Federal de Alfenas, no programa de pós-graduação em Estatística Aplicada e Biometria.



Ricardo Menezes Salgado, é bacharel em Matemática pela Universidade Federal de Viçosa, mestre e doutor em Engenharia Elétrica pela Universidade Estadual de Campinas. Atualmente é professor do Núcleo de Ciências da Computação da Universidade Federal de Alfenas. Atua na área de inteligência computacional, sendo consultor de diversos projetos em grandes empresas. Possui larga experiência na área de sistemas inteligentes, análise de dados e descoberta de conhecimento.



Luiz Alberto Beijo, licenciado em Matemática pela Pontifícia Universidade Católica de Minas Gerais, Mestrado e Doutorado em Estatística e Experimentação Agropecuária pela Universidade Federal de Lavras. Professor Associado da Universidade Federal de Alfenas atuando como coordenador do Programa de Mestrado em Estatística Aplicada e Biometria. Tem experiência de pesquisa na área de Probabilidade e Estatística, com ênfase em Estatística Aplicadas, atuando principalmente nos seguintes temas: modelos de regressão, teoria de valores extremos, inferência Bayesiana e Planejamento e análise de experimentos.