

# An Empirical Analysis of MLP Neural Networks Applied to Streamflow Forecasting

D. B. De Lima, M. D. C. E Lima and R. M. Salgado, *Member, IEEE*.

**Abstract**— Nowadays, in Brazil there is a large energy potential that comes from hydro mineral sources, which most part of the electricity consumed comes from this source. According to this, it is important emphasize that the decision-making related with planning of the operation of the reservoirs of hydroelectric plants has been done based mainly on preview knowledge of the flow. Thereby, this work aims to conduct an exploratory study about the Artificial Neural Networks type MLP to estimate which is the best setting to perform the stream flow forecast. This study was applied to the Rio Grande basin, in addition, with the achieved results, it was possible to observe that the search of appropriate parameters shows significant gains in the execution of the forecasts and can to reduce the error level obtained.

**Keywords**— Streamflow Forecasting, Power Systems Planning, Time Series Forecasting, Artificial Neural Networks Configuration.

## I. INTRODUÇÃO

A GERAÇÃO de energia elétrica consolida-se como uma atividade de extrema importância para a economia em geral. Devido à complexidade dos fenômenos hídricos, existe a necessidade de estabelecer modelos capazes de representar com nível de precisão satisfatório o comportamento da água. Neste sentido, a avaliação do comportamento hidrológico é utilizada para medir o impacto causado na construção de obras, em particular, novas usinas geradoras de eletricidade. Analogamente, esse tipo de estudo é importante às usinas para aprimorar suas regras de operação.

Os sistemas de reservatórios são normalmente submetidos a usos múltiplos e concorrentes (abastecimento humano, irrigação, produção de energia, entre outros). Para seu dimensionamento e operação geralmente utiliza-se de modelos determinísticos chuva-vazão e/ou de modelos de geração estocástica de vazão [1], dependendo principalmente da disponibilidade de dados.

O Brasil possui bacias hidrográficas compostas de centenas de rios permanentes e caudalosos e que se distribuem por todas as regiões do país. De acordo com [2], cerca de 66,22% da energia elétrica consumida no Brasil origina-se de usinas hidrelétricas sendo assim, o gerenciamento otimizado do uso da água pode resultar em uma grande economia nos recursos naturais disponíveis e, consequentemente aumentar a

disponibilidade energética de uma empresa geradora de energia.

O potencial energético de uma usina hidrelétrica é medido através da quantidade de água existente em seu reservatório. Para medir o nível de água nos reservatórios existem distribuídos ao longo dos rios que integram as bacias hidrográficas, pontos de medição específicos que fornecem medidas discretas da vazão, permitindo compor as séries históricas de aflúências. A quantidade de água em uma usina é controlada através da série temporal de vazões que reflete o comportamento hidrológico da bacia. A série temporal de vazões é, portanto, fundamental para a produção energética brasileira, já que mede o potencial de energia em uma usina. Entretanto, o planejamento de operações das hidrelétricas é comprometido pelo fato da série de vazões apresentarem uma alta aleatoriedade gerando incerteza em relação aos valores futuros [3] e, consequentemente, dificuldades de representação em termos de modelos matemáticos. Uma das formas de amenizar os impactos relacionados ao conhecimento do valor da vazão no futuro é via modelos de previsão de vazões. Prever a vazão significa descobrir, por antecipação, os valores da quantidade de água que irá fluir com base nas séries históricas disponíveis.

Na literatura, existem várias técnicas utilizadas para realizar a previsão de séries temporais, tais como: Redes Neurais Artificiais (RNAs) [4][20][21], Modelos Auto-regressivos [5], Modelos baseados em Lógica *Neuro-Fuzzy* [6], entre outros. Tradicionalmente, o setor elétrico usa para prever a vazão afluente, o método de Box-Jenkins [18],[19], que pressupõe uma relação linear entre os valores presente e passado da vazão, entretanto estes modelos não são os mais adequados para tratar um conjunto de dados com características não-lineares e não-estacionárias como às séries de vazão. No início da década de 1990, os modelos baseados em redes neurais artificiais começaram a ser utilizados para as tarefas de previsão obtendo sucesso entre os pesquisadores.

Entre os trabalhos na área destaca-se o artigo proposto por [7] no qual foi apresentada uma metodologia que realiza a previsão das vazões para a usina de Furnas seguindo um horizonte mensal. É utilizado um método baseado em regras *fuzzy* adaptativas, denominado A-FSM. Neste trabalho, os dados estão apresentados desde 1931 até 2005 seguindo uma discretização mensal, no qual representam o volume da vazão da Usina de Furnas. Para o ajuste do modelo de previsão foram utilizados os dados de 1931 até 1995 e os testes foram realizados para os anos de 1996 até 2005. Os resultados obtidos com o sistema A-FSM mostram um erro de 19,08%, o que é inferior aos erros obtidos por outros sistemas

D. B. DE Lima, Universidade Federal de Alfenas (UNIFAL-MG), Alfenas, Minas Gerais, Brasil, danilobraga@bcc.unifal-mg.edu.br

M. D. C. E Lima, Universidade Federal de Alfenas (UNIFAL-MG), Alfenas, Minas Gerais, Brasil, mariana@bcc.unifal-mg.edu.br

R. M. Salgado, Universidade Federal Alfenas (UNIFAL-MG), Alfenas, Minas Gerais, Brasil, ricardo@bcc.unifal-mg.edu.br

relacionados, tais como: C-FSM [8] que possui 20,19% e ANFIS [6] que apresenta 20,12%

Outro trabalho que se propôs a realizar a previsão de vazões para o posto de Furnas foi apresentado por [9]. Neste trabalho foi mostrado um modelo de previsão diário de vazão que utiliza a técnica de redes neurais. A previsão segue um horizonte de doze dias à frente, no qual, para cada dia é criada uma nova RNA com intuito de realizar a previsão para um dia específico. Os dados utilizados neste trabalho compõem uma série histórica diária de 1970 até 1980. O conjunto de treinamento é composto de dados dos períodos de 12/01/1970 à 17/07/1974 e 13/10/1978 à 31/12/1980. O conjunto de validação se estende de 18/07/1974 à 12/10/1978. Para avaliar o desempenho da rede o conjunto de verificação é composto dos dados de 12/01/1996 à 31/12/2000. Os resultados obtidos por este sistema foram superiores aos obtidos pelo modelo ETA [10], que é atualmente utilizado pelo Operador Nacional do Sistema Elétrico Brasileiro (ONS). Para o período que foi utilizado como base de testes os resultados do modelo ETA foram de 22% e o resultado obtido pela RNA foi de 13,7%.

Este estudo tem o intuito de investigar quais os valores mais adaptados para cada parâmetro do modelo foi realizada uma busca exaustiva em base mensal, visando encontrar um modelo otimizado para cada mês do histórico. Com os resultados encontrados foi possível definir intervalos específicos que devem ser utilizados para a obtenção de resultados promissores, na previsão de vazões, via modelo MLP. Os níveis de erro encontrados são compatíveis com os trabalhos existentes na literatura (nacional e internacional). A aplicação do método proposto atinge as quatro primeiras usinas da Bacia Rio Grande, o que evita o vício do modelo de dados para uma usina específica.

O conteúdo deste trabalho encontra-se organizado da seguinte forma: na Seção II são apresentados alguns conceitos sobre previsão de vazões, na Seção III é abordada a metodologia utilizada para realizar os experimentos, já na Seção IV é feita uma discussão sobre os dados utilizados para alimentar o modelo, na Seção V são mostrados os resultados obtidos e finalmente na Seção VI são feitas as considerações finais do trabalho.

## II. O PROBLEMA DA PREVISÃO DE VAZÕES

O sistema hidroelétrico brasileiro apresenta aspectos peculiares que o torna diferente dos outros sistemas. A geração da energia elétrica pelas hidrelétricas depende diretamente da vazão do rio correspondente, ou seja, da altura de água disponível em um determinado período e da sua queda. Esses comportamentos são observados através dos dados fornecidos pela ONS [16], que fornece relatórios anuais das vazões diárias e mensais de todas as usinas em operação no Brasil desde 1931. Nota-se que as vazões possuem um comportamento sazonal com periodicidade anual, ou seja, a curva de vazão apresenta um perfil histórico segue um padrão anual, conforme pode ser visto na Fig. 1.




Figura 1. Comportamento cíclico da vazão mensal de Furnas dos anos de 1995 até 2005.

O planejamento da operação dessas usinas depende do conhecimento prévio do volume da água disponível nesses reservatórios, ou seja, é preciso conhecer a quantidade de água que estará disponível, com certa antecedência, para que se possa, finalmente, estimar a quantidade máxima de energia a ser gerada pela usina. Logo, em função dos resultados da previsão das vazões é possível realizar o planejamento energético de modo a atingir níveis ótimos de geração de energia.

A previsão de vazões é a estimativa do valor das afluentes para um determinado período de tempo, no futuro. Ela é essencial para o planejamento das operações de uma hidrelétrica e proporciona subsídios para a tomada de decisões podendo provocar ganhos expressivos. Além disso, previsões de vazões permitem a tomada de decisões em relação às cheias excepcionais, desde que feita com relativa previsão e antecedência [11].

O período de tempo no futuro que se deseja prever é chamado de horizonte de previsão. No setor elétrico os horizontes, de relacionados a previsão de vazões, estão divididos em três tipos: curto, médio e longo prazo [17]. Previsões de curto prazo utilizam dados de vazões diárias e realizam a previsão para até 14 dias à frente, previsões de médio porte analisam os dados de vazões semanais para prever até seis semanas à frente [11]. E a previsão de longo prazo é utilizada para avaliar riscos de ocorrência de vazões num determinado local, como por exemplo: o risco de inundação numa seção de um rio, a probabilidade de períodos úmidos e secos, dentre outros.

## III. METODOLOGIA

As arquiteturas do tipo MLP, adotadas neste estudo, representam os modelos de redes neurais mais conhecidos e utilizados atualmente. Uma MLP consiste de  $n$  nós de entrada,  $h$  camadas de nós escondidos (intermediários) e  $m$  nós de saída conectados de uma maneira realimentada a partir de pesos multiplicativos  $W$ . A MLP deve ser treinada com dados históricos para encontrar os valores apropriados de  $W$  e o número de neurônios requeridos na camada escondida. Existem diversas formas de treinar uma rede neural do tipo MLP. Neste trabalho, a técnica de treinamento utilizada foi o algoritmo de retro-propagação do erro (*backpropagation*) [12].

O processo de encontrar os parâmetros de configuração de uma MLP não é trivial devido à influência de diversos fatores, tais como: definição do número de camadas, escolha do

número de neurônios, o tipo de função de ativação e também os termos *momentum* e a taxa de aprendizagem. Nos estudos exploratórios realizados, o modelo foi submetido a uma série de testes para verificar a estabilidade levando em consideração a configuração dos parâmetros.

Um parâmetro que é comumente utilizado para se realizar previsões é o número de atrasos que compõem os padrões para a previsão. Neste trabalho, os padrões utilizados pelo modelo foram os meses imediatamente anteriores ao mês a ser previsto. Desta forma, o número de atrasos corresponde à quantidade de meses que serão levados em consideração para a composição do padrão. A Tabela I exemplifica um padrão utilizado pelo sistema com seis atrasos, onde a previsão será realizada para o mês de janeiro de 1998 e os meses de julho até dezembro de 1997 são utilizados como entradas para o modelo. Neste caso  $t$  representa apenas uma generalização do padrão utilizado pelo modelo, no qual  $t-n$  são as componentes do padrão utilizadas como entrada e  $t+1$  é a saída desejada do modelo.

TABELA I  
FORMAÇÃO DOS PADRÕES DE ENTRADA PARA O MODELO MLP.

	Entradas						Saída Desejada
Mês	jul	ago	set	out	nov	dez	Jan
Série	$t-5$	$t-4$	$t-3$	$t-2$	$t-1$	$T$	$t+1$

Neste trabalho serão apresentados dois processos de treinamento para a MLP: **Treinamento Único** e **Treinamento Contínuo**. No processo de **Treinamento Único**, o modelo é treinado até certo ponto. A partir de então, é realizada a previsão para instantes posteriores, sem que haja novo treinamento. Vale lembrar que para realizar a previsão de um determinado instante, são gerados diversos modelos com o intuito de encontrar o mais adaptado. Na metodologia de **Treinamento Contínuo**, sempre se utiliza o instante anterior ao previsto para auxiliar no ajuste do previsor, ou seja, a todo novo instante (mês) a ser previsto, o instante anterior (mês) é utilizado como parte dos dados para realizar o treinamento do modelo (Tabela II).

TABELA II  
EXEMPLO DE PADRÕES DE TREINO, VALIDAÇÃO E TESTE.

Matriz Treino					
jul/86	ago/86	...	dez/86	jan/87	
⋮	⋮		⋮	⋮	
jul/31	ago/31	...	dez/31	jan/32	
Matriz Validação					
jul/95	ago/95	...	dez/95	jan/96	
⋮	⋮		⋮	⋮	
jul/87	ago/87	...	dez/87	jan/88	
Padrão Teste					
jul/96	ago/96	...	dez/96	jan/97	

O exemplo de aplicação visto na Tabela II, da metodologia de **Treinamento Contínuo** apresenta os dados para previsão do mês de janeiro de 1998. Neste caso, os dados de treinamento da rede seriam as vazões do mês de janeiro de 1932 até 1987, a validação foi definida a partir dos anos de 1988 até 1996 e o teste aplicado no ano de 1997. É importante visar a necessidade da criação de um modelo de previsão específico de cada mês para que seja mantida a sazonalidade entre os meses do ano.

Após a seleção dos dados é necessário realizar o estudo exploratório sobre os parâmetros. Neste trabalho as configurações da MLP foram determinadas com base nos valores da Tabela III.

TABELA III  
ESPAÇO DE BUSCA DOS PARÂMETROS ESTRUTURAIS DA MLP.

Número de Camadas	[3 - 8]
Número de Neurônios	[1 - 12]
Taxa Aprendizagem	[0.0 - 1.0]
Termo <i>Momentum</i>	[0.0 - 1.0]
Função de Ativação	[Tan Hiperbólica, Logística]

Para encontrar os melhores parâmetros, o experimento ocorreu da seguinte forma: foram realizadas 500 modelos para as usinas definidas, onde os parâmetros da MLP foram estimados aleatoriamente através de uma busca exaustiva no domínio apresentado. Desta forma foi possível encontrar os parâmetros que poderiam ser os mais adaptados para este modelo de previsão.

A Fig. 2 ilustra o processo de busca exaustiva para a determinação dos resultados e para a definição dos parâmetros do modelo. O menor erro percentual em relação ao resultado real foi o critério adotado para a escolha dos parâmetros mais adaptados ao problema. O erro foi calculado com base na média de previsão dos cinco melhores resultados obtidos nos padrões de validação. A escolha destes resultados permite definir qual é o intervalo que estão os parâmetros adaptados ao problema. Para analisar a estabilidade destes parâmetros selecionados, foram realizados novos experimentos e geradas 10 previsões para cada usina.

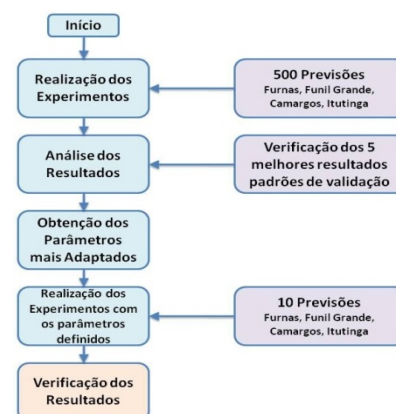


Figura 2. Processo de Busca Exaustiva.

#### IV. ANÁLISE DE DADOS

Os dados utilizados neste trabalho são disponibilizados pelo Operador Nacional do Sistema – ONS [13] e estão armazenados em arquivos que foram discretizados seguindo um horizonte mensal dos anos de 1931 até 2007 que representam o fluxo médio de vazão. Em [14] (apud [4] p. 2) é mostrado o processo de obtenção dos dados das vazões que é considerado complexo e baseado em medições e análises (Fig. 3).

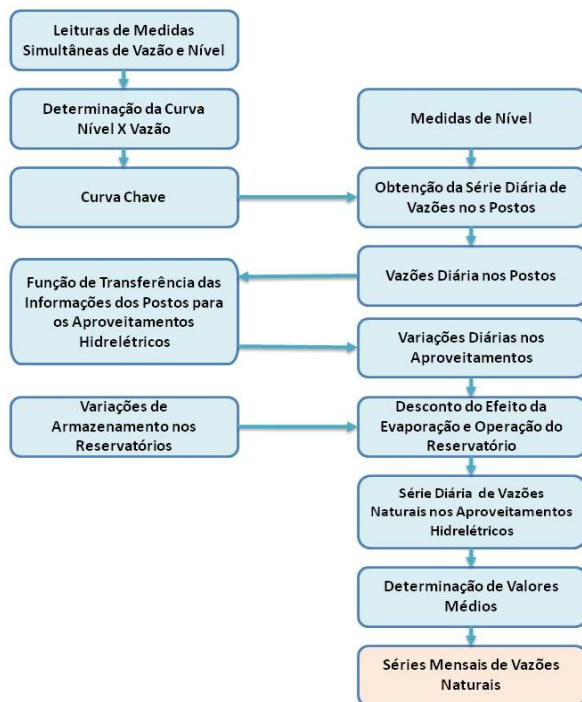


Figura 3. Processo de obtenção dos dados das vazões. [14] (apud [4] p. 2).

Nesta pesquisa foram utilizados dados referentes às usinas de Camargos, Itutinga, Funil Grande e Furnas. A Tabela IV mostra o máximo, o mínimo, a média, desvio padrão e o coeficiente de variação das séries de vazões destas usinas. Como é possível perceber na tabela, o coeficiente de variação apresenta um comportamento irregular de alta variabilidade nos dados, o que dificulta a previsão com um nível maior de acertos.

TABELA IV  
MEDIDAS ESTATÍSTICAS DOS DADOS DE VAZÕES.

Usina	Máx.	Min.	Méd.	Desv. Pad.	Coef. Var.
Camargos	576m <sup>3</sup> /s	34m <sup>3</sup> /s	132,8m <sup>3</sup> /s	84,3 m <sup>3</sup> /s	63,47%
Itutinga	576m <sup>3</sup> /s	34m <sup>3</sup> /s	132,9m <sup>3</sup> /s	84,4 m <sup>3</sup> /s	63,49%
Funil Grande	1288m <sup>3</sup> /s	68m <sup>3</sup> /s	305,1m <sup>3</sup> /s	197,4m <sup>3</sup> /s	64,71%
Furnas	3757m <sup>3</sup> /s	204m <sup>3</sup> /s	926,6m <sup>3</sup> /s	612,5m <sup>3</sup> /s	66,11%

Para ilustrar esta variabilidade nos dados, a Fig. 4 mostra um gráfico com as séries que foram utilizadas para realizar as previsões, que vão desde janeiro de 1996 até dezembro de

2005. Neste gráfico é possível observar a grande diferença existente no conjunto de dados referentes às vazões de uma hidrelétrica.




Figura 4. Séries de Vazões das Usinas: Camargos, Itutinga, Funil Grande e Furnas – Jan/96-Dez/05.

Para o bom funcionamento de um modelo computacional de previsão é importante que a base de dados a ser utilizada use um processo de normalização. Com esta abordagem ocorre a padronização dos dados dentro de limites pré-definidos para que o desvio apresentado não seja muito alto.

Considerando essa ressalva, foi-se adotada a política de normalização dos dados utilizados para valores entre 0 e 1. Este processo não acarretou na perda da representatividade dos dados normalizados em relação aos dados brutos.

Um fator interessante é a relação entre a média e o desvio padrão das vazões mensais no decorrer do histórico. Observa-se que nos meses de cheia (Novembro a Março) há uma diferença significativa nos valores médios em relação aos meses de seca (Junho a Setembro), o mesmo ocorre em relação ao desvio padrão. Esta diferença pode causar prejuízo no processo de previsão nos meses de cheia devido ao maior coeficiente de variação reportado nestes meses. A Fig. 5 colabora para visualização destas informações para o posto de Furnas no período de 1931 a 2007.




Figura 5. Média e Desvio Padrão do Posto de Furnas – Jan/31-Dez/07.

#### V. ESTUDOS DE CASOS

Os estudos de caso de previsão executados neste trabalho foram aplicados nas quatro primeiras usinas do Rio Grande (Camargos, Itutinga, Funil Grande e Furnas). O modelo de previsão utilizado neste trabalho é composto por uma fase de treinamento, no qual os parâmetros são ajustados, e uma fase



de testes, no qual é verificado o desempenho do modelo com os parâmetros já definidos. O período de treinamento do modelo foi formado com dados dos anos de 1931 até 1995 e a partir da rede treinada com estes anos, os dez anos posteriores foram previstos, ou seja, de 1996 até 2005. Parte do conjunto de treinamento foi utilizada para criar o conjunto de validação, que possibilitou a seleção dos melhores modelos para a etapa de testes. Com o objetivo de avaliar e comparar o desempenho dos resultados obtidos foi adotado o erro relativo médio (ERM), apresentado na equação (1):

$$ERM = \frac{1}{n} \sum_{i=1}^n \left| \frac{x_i - \hat{x}_i}{x_i} \right| \quad (1)$$

no qual  $x_i$  é o valor real e  $\hat{x}_i$  é o valor previsto.

A Fig. 6 representa a metodologia utilizada para a realização dos testes, na qual nota-se que são realizadas as previsões para as usinas em questão, utilizando-se de o **Treinamento Único** e **Treinamento Contínuo**. Dessa forma, será possível perceber qual a influência de se realizar o treinamento a cada ano previsto.




Figura 6. Metodologia utilizada para realizar a previsão.

Considerando o processo de previsão com **Treinamento Único**, a Fig. 7 ilustra a média de erro encontrada. Nessa figura é possível perceber que os meses que possuem maior valor de precipitação tendem a apresentar uma variação maior, logo o modelo apresenta erros mais elevados (meses de cheia). Entre os meses de seca, especificamente, Junho a Agosto, os resultados encontrados apresentam erros significativamente inferiores ao valor médio encontrado ao longo dos anos de previsão.




Figura 7. Previsão Treinamento Único (1996 - 2005). Usinas: Camargos, Itutinga, Funil Grande e Furnas.

A Fig. 8 apresenta os erros obtidos pelo modelo de previsão baseado em **Treinamento Contínuo**. Pelos resultados pode-se

observar um comportamento similar entre o período de seca e cheia se levado em consideração os resultados da Fig. 7. Nota-se também que os resultados do modelo baseado no **Treinamento Contínuo** apresentam erros significativamente elevados se observado os meses de Janeiro, Fevereiro e Outubro em relação ao modelo executado com **Treinamento Único**. Nesta figura é possível visualizar de forma mais clara a variação apresentada nos meses de maior precipitação, no qual, por exemplo, para a Usina de Furnas o erro médio em julho chegou a somente 5%.




Figura 8. Previsão Treinamento Contínuo (1996 - 2005). Usinas: Camargos, Itutinga, Funil Grande e Furnas.

A partir da Fig. 7 e Fig. 8, é possível perceber que a previsão com **Treinamento Contínuo** apresentou melhores resultados. Isto ocorre porque a rede passa por um treinamento que leva em consideração novas informações históricas a medida que a previsão é executada, este fator torna a rede adaptada aos fatores que ocorrem em meses próximos aos meses que serão previstos aumentando o desempenho. É possível notar que a previsão com **Treinamento Único**, apesar de apresentar um erro maior, possui uma taxa de erro com menor variação ao longo dos meses, não apresentando grandes distorções entre a previsão para um mês de seca e um mês de cheia. Este fato ocorre porque como a rede é treinada apenas uma vez, e esta acaba se estabilizando tendendo a uma faixa de erros constante para todos os meses previstos.

A Fig. 9 ilustra a previsão para os dez anos para o posto de Furnas seguindo uma discretização mensal, tomando como base os resultados do modelo MLP **Treinamento Contínuo**. Nesta Figura, é possível visualizar a sequência completa de previsões realizadas sobre os anos desejados, assim como os valores reais das vazões. Nota-se que o modelo foi capaz de estimar os picos e vales do histórico de vazões com precisão.




Figura 9. Previsão real e desejada – Furnas (1996 - 2005).

Para facilitar a análise dos resultados obtidos através do modelo de previsão, a Tabela V apresenta uma visão geral sobre a média de erros que obtidos nas simulações deste trabalho.

TABELA V  
ERRO RELATIVO MÉDIO APRESENTADOS PELO MODELO MLP

Furnas		Funil Grande	
Treinamento Contínuo	19,48%	Treinamento Contínuo	17,07%
Treinamento Único	20,79%	Treinamento Único	18,80%
Camargos		Itutinga	
Treinamento Contínuo	16,85%	Treinamento Contínuo	16,66%
Treinamento Único	19,58%	Treinamento Único	19,79%

A partir dos experimentos realizados e considerando a busca exaustiva dos parâmetros quem compõem o modelo MLP foi possível identificar qual a faixa de valores que mais se adaptaram para realizar a previsão de vazões no período desejado. A Tabela VI mostra quais valores ocorrem com maior frequência entre os modelos com menor nível de erro.

TABELA VI  
INTERVALO DE PARAMETROS SELECIONADO PARA O MODELO MLP.

Número de Camadas	[3 - 4]
Número de Neurônios	[9 - 10]
Taxa Aprendizagem	[0.1 - 0.2]
Termo <i>Momentum</i>	[0.4 - 0.6]
Função de Ativação	[Tan Hiperbólica, Logística]

Para testar a estabilidade do modelo seguindo a configuração dos parâmetros definidas, foi realizado um estudo de previsão durante 10 anos diferentes dos anos já previstos (houve mudanças nos arquivos de treinamento e validação). O objetivo principal destes testes foi verificar se o modelo se comportava de forma consistente com outros padrões de entrada. As previsões foram executadas para os anos de 1976 até 1985 para as usinas já definidas utilizando-se somente o processo de previsão com *Treinamento Contínuo*. A Fig. 10 apresenta o gráfico contendo a média de erro obtida pelo predictor. A partir destes resultados foi possível perceber que o modelo foi capaz de prover resultados interessantes com uma variação similar ao período de previsão executado no estudo anterior.




Figura 10. Previsão Treinamento Contínuo (1976 - 1985). Usina: Camargos, Itutinga, Funil Grande e Furnas.

Após a realização dos experimentos foi possível identificar nos parâmetros das redes uma configuração, que na média das previsões, teve maior adaptação para realizar a previsão de vazões, estes parâmetros são: **4** camadas intermediárias, **10** neurônios, taxa de aprendizagem de **0.2**, *termo momentum* igual a **0.5** e *Tangente Hiperbólica* como função de ativação. Seguindo estas configurações, e realizando a previsão para a usina de Furnas nos 10 anos utilizados anteriormente, este modelo apresentou erro médio de 19,94%.

Em contrapartida, foi escolhida uma configuração aleatória dos parâmetros, que não necessariamente, estavam dentre a faixa de parâmetros pré-definida. Os parâmetros encontrados foram: **1** camada intermediária, **15** neurônios, taxa de aprendizagem de **0.6**, *termo momentum* igual a **0.9** e Logística como função de ativação. Com estas configurações, os resultados apresentaram um erro médio de 26,86%, com isso é possível perceber a influência da escolha de bons parâmetros no processo de configuração das MLP com o intuito de realizar a previsão de vazões.

## VI. CONCLUSÃO

Este trabalho apresenta um estudo sobre as previsões de vazões realizadas sobre quatro usinas localizadas no Rio Grande. Com os resultados obtidos foi possível perceber a capacidade das redes neurais do tipo MLP como alternativa promissora na previsão de vazões. A principal contribuição deste trabalho foi a análise exaustiva dos parâmetros dos modelos MLP que possibilitou a descoberta de uma faixa de valores de configuração capazes de produzir melhores resultados, no problema analisado.

O nível de erro obtido nas simulações de previsão foi compatível, e em alguns casos inferiores, frente a outros trabalhos existentes na literatura. Para propostas futuras, sugere-se a realização de novas simulações levando em consideração outros postos de vazões bem como a aplicação da análise exploratória em outras técnicas de previsão a fim de obter resultados com maior nível de precisão. Pode-se também realizar um estudo exploratório em outros horizontes de previsão de vazões para constatar se a faixa de valores encontrada neste trabalho pode ser replicada para a previsão em outros instantes de tempo.

## REFERÊNCIAS

- [1] R. M. Salgado, "Sistema de Suporte à Decisão para Previsão de Carga por Barramento. 2009". 238f. Tese de Doutorado – Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas (UNICAMP), Campinas, 2009.
- [2] Agência Nacional de Energia Elétrica, ANEEL. "Matriz de energia elétrica", 2011. Disponível em <http://www.aneel.gov.br/>. Acessado em 31-out-2011.
- [3] H. A. O. Silva, "Power Map Explorer: Uma Ferramenta para visualização e previsões de vazões". 2007. 112f. Tese de Mestrado – Instituto de Ciências Matemáticas e de Computação – ICMC/USP, Universidade de São Paulo (USP), São Carlos, 2007.
- [4] R. Ballini, "Análise e Previsão de Vazões Utilizando Modelos de Séries Temporais, Rede Neurais e Redes Neurais Nebulosas". 2000. 187f. Tese de Mestrado – Faculdade de Engenharia Elétrica e de Computação, Universidade de Campinas (UNICAMP), Campinas, 2000.

- [5] G. E. P. Box, G. M. Jenkins, "Time Series Analysis, Forecasting and Control", San Francisco: Holden Day, 575 págs, Revised Edition, California, USA, 1976.
- [6] J. S. R. Jang, "ANFIS: Adaptive Network Based Fuzzy Inference System". IEEE Transaction System, Man and Cybernetics. 2003
- [7] I. H. Luna, R. Ballini, S. Soares, "An Adaptive Hybrid Model for Monthly Streamflow Forecasting". In: The IEEE International Conference on Fuzzy Systems - FUZZ-IEEE'07, Proceedings of the IEEE International Conference on Fuzzy Systems, . p. 1-6., London, 2007.
- [8] I. H. Luna, R. Ballini, S. Soares, "A Constructive-Fuzzy System Modelling for Time series Forecasting". In: International Joint Conference on Neural Networks – IJCNN'07, Proceedings of the International Joint Conference on Neural Networks - IJCNN'07, 2007. p. 1-6, Orlando, Flórida..
- [9] I. H. Luna, R. Ballini, S. Soares, "Previsões de curto prazo de vazão afluente ao reservatório de Furnas utilizando redes neurais artificiais". Revista Brasileira de Recursos Hídricos, v. 13, p. 77-88, 2008.
- [10] M. Cataldi, C. O. Machado, L. G. F. Guilhon, "Análise das previsões de precipitação obtidas com a utilização do modelo Eta como insumo para modelos de previsão semanal de vazão natural". 556.18, v12, n 3. Revista Brasileira de Recursos Hídricos - RBRH. Porto Alegre: ABRH, v.12, n.3, jul/set. 2007. 219 p.
- [11] L. G. F. Guilhon, "Modelo heurístico de previsão de vazões naturais médias semanais aplicada à usina de foz do areia". 2002. 88f. Tese de Doutorado – Programa de Engenharia de Sistemas e Computação (COPPE). Universidade Federal do Rio de Janeiro (UFRJ), Rio de Janeiro, 2002.
- [12] D. Rumelhart, G. Hinton, R. Williams, "Learning internal representation by error propagation, parallel distributed processing: Explorations in the Microstruture of Cognition", 1986, Vol. 1, MIT Press, Cambridge.
- [13] Operador Nacional do Sistema - ONS. "Séries de Vazões Mensais", 2009. Disponível em <http://www.ons.org.br/download/> Acessado em 21-nov-2009.
- [14] L. A. M. Fortunato, T. A. A. Neto, J. C. R. Albuquerque, e C. Ferreira, "Introdução ao Planejamento da Expansão e Operação de Sistemas de Produção de Energia Elétrica". 1990. Editora Universitária, Niterói, Rio de Janeiro.
- [15] R. Krauskopf Neto, "Atualização de Modelos Chuva-Vazão – Propagação Com Estimador de Estado". 2005. 264f. Tese de Mestrado, Departamento de Engenharia Hidrológica, Universidade Federal do Paraná. Curitiba, 2005.
- [16] Operador Nacional do Sistema Elétrico, ONS. Disponível em <http://www.ons.org.br/>. Acessado em 28-fev-2011.
- [17] S. Soares Filho, "Planejamento da Operação de Sistemas Hidrotérmicos", 1987, SBA: Controle de Automação. Vol. I, N° 2, pp 122-131.
- [18] G. E. P. Box, and Jenkins, G. M., 1976. Time Series Analysis: Forecasting and Control. California, USA. San Francisco: Holden Day, 2nd. ed.
- [19] C. J. Hoff, 1983. A Practical Guide to Box-Jenkins Forecasting, Belmont, CA.,USA, Lifetime Learning Publications.
- [20] C. Oliveira, F. Ferro, R. Wazlawick, R. Bastos, "Improvement of the Short Term Load Forecasting Through the Similarity Among Consumption Profiles", IEEE LATIN AMERICA TRANSACTIONS, Vol. 7, No. 5, pp. 527-532, Sept. 2009.
- [21] D. S. Ramos, T. E. D. C. Huayllas, "Electric Power Forecasting Methodologies of Some South American Countries: A Comparative Analysis", IEEE LATIN AMERICA TRANSACTIONS, Vol. 8, No. 5, pp. 519-525, Sept. 2010.



**Mariana Dehon Costa e Lima** é graduanda em Ciência da Computação pela Universidade Federal de Alfenas (UNIFAL-MG). Atualmente trabalha na área de inteligência artificial aplicada para série de vazões em problemas de séries sintéticas e previsão. Utiliza as técnicas de Redes Neurais e Máquina de Vetores Suporte (SVM). É membro do grupo de pesquisa do Laboratório de Inteligência Computacional (LIInC).



**Ricardo Menezes Salgado** é Bacharel em Matemática pela Universidade Federal de Viçosa (2002), mestre (2004) e doutor (2009) em Engenharia Elétrica pela Universidade Estadual de Campinas. Atualmente é professor da Universidade Federal de Alfenas, lotado no curso de Ciência da Computação. Atua na área inteligência computacional, sendo consultor e executor de diversos projetos em grandes corporações. Tem experiência como desenvolvedor de sistemas inteligentes de suporte a decisão (plataforma JAVASE) e em análise de dados com ênfase em séries temporais. Ao longo de sua carreira tem atuado principalmente nos seguintes temas: inteligência computacional, previsão de séries temporais, mineração de dados, otimização e reconhecimento de padrões aplicados em diversos setores.



**Danilo Braga Lima** é graduado em Ciência da Computação pela Universidade Federal de Alfenas (UNIFAL-MG). Trabalha na área de inteligência artificial aplicada para série de vazões em problema de previsão e utilizando ensembles, utilizando principalmente Redes Neurais. É membro do grupo de pesquisa do Laboratório de Inteligência Computacional (LIInC).