

MODELO BASEADO EM COMBINAÇÃO DE PREVISORES PARA PREVISÃO DE SÉRIES TEMPORAIS DE CARGA ELÉTRICA

MODEL BASED ON COMBINATION OF PREDICTORS FOR SHORT-TERM LOAD FORECAST

Max Olinto Moreira^{1,2}; Ricardo Menezes Salgado^{1,2}; Takaaki Ohishi²; Eric Batista Ferreira¹

¹Universidade Federal de Alfenas – UNIFAL-MG – Alfenas/MG – Brasil

{max, ricardo}@bcc.unifal-mg.edu.br

eric@unifal-mg.edu.br

²Universidade Estadual de Campinas – UNICAMP – Campinas/SP – Brasil

taka@densis.fee.unicamp.br

Resumo

A previsão da demanda de carga é uma tarefa fundamental para um bom funcionamento dos sistemas elétricos, pois vários processos de tomada de decisão, tais como planejamento, operação, análise de segurança e decisões de mercado, são altamente influenciados por este processo. Sabendo que o atendimento da demanda de carga é um processo estocástico, esta previsão se mostra importante para que uma empresa de distribuição promova um fornecimento de energia de forma segura, econômica e contínua. Nesta ótica, este trabalho propõe a elaboração de uma metodologia de previsão de carga à curto prazo, baseada na combinação de vários previsores distintos. Os resultados alcançados mostraram que a combinação dos previsores apresentou, na maioria dos casos analisados, resultados mais acurados quando comparados aos resultados obtidos por apenas uma componente de previsão individualmente. Neste modelo, a previsão da curva de demanda de carga baseia-se nas curvas de demanda de dias já conhecidos.

Palavras-chave: Previsão de Carga, Combinação de Previsores, Inteligência Artificial, Planejamento de Sistemas de Potência.

Abstract

The forecasting of load demand is a fundamental task for the proper functioning of electrical systems, because many decision-making processes such as planning, operation, security analysis and market decisions are highly influenced by this process. Knowing that meet the demand charge is a stochastic process, this prediction proves important to a energy company to operate safely and economically. From this viewpoint, this paper proposes the development of a methodology for load forecasting in the short term, based on a combination of several different predictors. The results showed that the combination of the predictors presented in most cases examined, more accurate results when compared to results obtained for only a forecast component individually. In this model, the forecast of the load demand curve was based on demand curves for known days.

Key-words: Load Forecasting, Ensemble Model, Artificial Intelligence, Power System Planning.

1. Introdução

A busca por uma maneira de preservar e otimizar a utilização da energia em geral tem sido alvo de estudos. A energia elétrica, por ser um insumo indispensável ao desenvolvimento econômico das sociedades atuais, tem uma tendência positiva ao consumo. Para que o fornecimento de energia elétrica aconteça com boa qualidade, de forma segura, econômica e contínua, uma empresa precisa dispor de técnicas que estimem, com a máxima exatidão, o nível de demanda, para que se procure atingir um equilíbrio entre a energia gerada e a consumida.

Com a finalidade de se obter melhorias na programação e no planejamento operacional de uma empresa de distribuição de energia, várias estratégias têm sido utilizadas e criadas. É possível mencionar, como uma dessas estratégias, o aperfeiçoamento ou melhoramento de componentes utilizados na previsão de carga elétrica, procurando sempre otimizar os resultados. Associado à etapa de programação da operação, existe uma relação entre esta e o problema de previsão de carga à curto prazo.

Diante desta ótica, percebe-se que, um desequilíbrio, tanto da energia gerada em excesso quanto da energia gerada em quantidade menor que o necessário, pode causar problemas de sobre-tensão ou sub-tensão no sistema. Existem duas soluções possíveis para tentar amenizar este problema ou tentar promover um equilíbrio entre a escassez e o excesso de energia, das quais podemos destacar: a reprogramação das geradoras ou a transferência de energia através dos intercâmbios entre os sistemas. Entretanto, de acordo com Salgado (2006), estas atividades demandam certo intervalo de tempo para serem efetivadas e daí surge a motivação de se realizar uma boa previsão.

Almejando obter resultados mais acurados no processo de previsão, assim como em Salgado (2006), neste trabalho é apresentada uma metodologia de previsão de carga elétrica baseada na combinação de diversos previsores distintos. Em concordância com Leone Filho (2006), acredita-se que este resultado, quando combinado, tende a apresentar soluções melhores ou iguais às soluções apresentadas pelas melhores componentes individuais, suavizando os erros e otimizando os resultados. A abordagem discutida neste trabalho envolve os seguintes modelos: Rede Neural Artificial (RNA), Programação Genética (PG) e Regressão Linear Múltipla (RLM).

A técnica de combinar ou agrupar os resultados de previsão originou-se do trabalho de Hansen e Salamon (1990), que demonstrou que a habilidade de generalização pode ser significativamente melhorada por meio da composição de várias redes neurais artificiais, ou seja, a partir do treinamento independente de várias destas e a posterior composição das saídas individuais. Ela consiste na combinação dos resultados de vários previsores (ou componentes) distintos para a

obtenção de uma saída que seja melhor (ou mais estável) que as obtidas pelos componentes individuais.

Existem diversos outros trabalhos na literatura que também focam na previsão de carga, geralmente utilizando uma combinação de previsores ou dos resultados de previsão. Dentre estes, pode-se citar também os trabalhos de Li et al. (2009), Siwek e Osowski (2007), Drezga e Rahman (1999) e Sapeluk et al. (1994). Neste sentido, a motivação deste projeto foi desenvolver metodologias que possibilitem estabelecer a previsão de carga elétrica à curto prazo buscando alcançar a máxima precisão nos resultados.

Para realizar a previsão da curva de demanda de carga de um determinado dia, o processo baseia-se nas curvas de consumo de dias já conhecidos. O modelo demonstrou uma boa capacidade de extração de características das componentes envolvidas na combinação, uma vez que os resultados obtidos pela maior parte destes, muitas vezes, superava numericamente ou muito se aproximava do resultado da melhor componente individual verificada.

Para tanto, este trabalho procurou investigar a previsão de carga horária para uma determinada semana de teste. Esta previsão, associada à combinação dos resultados obtidos pelas componentes individuais, demonstrou diversidade nos resultados, permitindo uma análise interessante dos resultados. Foi possível observar que os resultados combinados superavam ou muito se aproximavam dos resultados obtidos pelas melhores componentes, quando tratadas individualmente.

A organização do conteúdo deste artigo se dá de forma que a seção 2 apresenta a metodologia proposta, a seção 3 apresenta as componentes individuais, a seção 4 apresenta a base de dados utilizada, a seção 5 apresenta os resultados obtidos e a seção 6 aborda as conclusões.

2. Metodologia Proposta

O consumo diário, com discretização horária, pode ser representado através de uma série temporal. Estas séries de dados são aplicadas no treinamento de modelos de previsão com a finalidade de se obter um valor de carga que mais se aproxime da demanda real. Segundo Leone Filho (2006), a utilização de múltiplos previsores tenta explorar o bom comportamento local de cada um dos previsores e, com isto, aumentar a precisão e a confiabilidade da previsão, uma vez que se um dos previsores errar muito em determinado subconjunto de dados de entrada, os outros previsores tendem a compensar o erro.

Contudo, a ideia principal do modelo proposto consiste em realizar a previsão horária e combinar os resultados obtidos. Foi reservada a última semana do histórico para a realização dos experimentos, sendo esta a semana de teste. Desta forma, a previsão foi realizada hora a hora para

cada dia da semana considerada. A base de dados utilizada foi dividida em três partes (conforme visto na Figura 1) sendo que a primeira parte ficou reservada para treinamento, a segunda para validação e a terceira para teste. A princípio, a execução deste processo de previsão se deu utilizando apenas componentes de previsão, tratadas individualmente.



Figura 1 – Exemplo de um esquema de divisão do histórico de consumo de carga.

Fonte: Autoria própria (2011)

Partindo deste ambiente, foram selecionadas aquelas componentes que obtiveram os menores índices de erro de previsão, na semana de validação. Uma vez selecionadas, estas são utilizadas para efetuar a previsão horária para cada dia da semana de teste. Por fim, os resultados desta última previsão são combinados e uma análise comparativa entre os erros de previsão é abordada. A fórmula para cálculo destes erros e os critérios de seleção das componentes serão apresentados de forma mais detalhada ao longo deste trabalho.

Contudo, não há garantia de que, para qualquer aplicação, esta combinação irá de fato melhorar o desempenho da previsão se comparado com o melhor componente individual. Uma vez concebida a ideia, é apresentada na Figura 2, apenas em caráter de exemplo, uma combinação dos resultados de quatro previsores distintos.




Figura 2 – Esquema de um combinador de resultados de quatro previsores distintos

Fonte: Autoria própria (2011)

Neste trabalho foram utilizados três modelos para realizar a previsão das séries temporais de carga elétrica: Redes neurais artificiais, do tipo MLP, (Haykin (1994)), a programação genética (Koza (1992)) e a regressão linear múltipla (Draper e Smith (1981)).

Os dados utilizados na realização dos experimentos deste trabalho foram obtidos de uma empresa elétrica da região nordeste do Brasil. O período do histórico de medição compreende o intervalo que abrange as datas de 01/03/2002 a 31/08/2002, com discretização horária. Desta forma, foi efetuada a previsão da última semana do histórico de dados.

2.1. Componentes de Previsão

As componentes de previsão atuam como previsores individuais no ambiente discutido. Cada componente foi gerada a partir da variação aleatória dos parâmetros dos três modelos citados anteriormente, para realizar a previsão dos dias efetivamente. Estas componentes geradas realizam a previsão hora a hora para um determinado dia da semana de validação. Visando verificar o desempenho das componentes, são calculados os erros de previsão.

O erro percentual médio horário (EPMh), apresentado em (1), é calculado para cada hora de previsão do dia considerado. Nesta equação, χ_{Real} representa o valor real do consumo de carga para um determinado horário e $\chi_{Previsto}$ representa o valor de carga previsto para o mesmo horário. A partir do EPMh, é calculado o erro percentual médio diário (EPMd), apresentado em (2), o qual caracteriza o erro total cometido pela componente naquele dia.

$$EPMh = \frac{(\chi_{Real} - \chi_{Previsto})}{\chi_{Real}} \times 100 \quad (1)$$

$$EPMd = \frac{\sum_{i=0}^{23} (EPMh)_i}{24} \quad (2)$$

Portanto, estabelecidas as formas de cálculo dos erros, o processo de seleção das componentes ocorre em função daquelas que obtiveram o menor EPMd.

2.2. Combinadores

Os combinadores desempenham um papel ímpar no cenário de previsão. Neste trabalho, foram utilizadas três formas de combinar os resultados das componentes de previsão, das quais citam-se a média aritmética, a média ponderada e um modelo não-linear baseado em redes neurais artificiais multicamadas.

A primeira forma consiste no uso de média aritmética (3) sobre os resultados das melhores componentes, selecionadas a partir do menor EPMd. Nesta equação, χ_i , representa os valores de carga para um determinado horário, previstos por cada componente, e “n” representa o número total de componentes selecionadas.

$$\overline{MA} = \frac{(\chi_1 + \chi_2 + \dots + \chi_n)}{n} \quad (3)$$

A segunda maneira de se construir o combinador consiste no uso da média ponderada (4) sobre os resultados das melhores componentes selecionadas. Nesta equação, ω representa os pesos, distribuídos de forma que as componentes que alcançaram menores índices de erros recebem os maiores valores no processo e χ_i denota os valores previstos. Considerando que o número de componentes pode variar, a distribuição dos pesos também varia, mas sempre fazendo com que as que obtiveram os menores EPMd's recebam uma porção maior do total de pesos. Esta distribuição dos pesos foi realizada de forma empírica. Para tanto, foi definida uma métrica para a distribuição dos pesos, de forma que se apenas 2 componentes forem selecionadas, os pesos ficam empiricamente divididos de maneira que a componente que obteve o menor EPMd recebe peso 60 e a segunda componente recebe peso 40. Se apenas 3 componentes foram selecionadas, a distribuição dos pesos fica empiricamente definida como 50 para a que obteve o menor EPMd, 30 para a segunda componente e 20 para a última.

$$\overline{MP} = \frac{(\omega_1 \chi_1 + \omega_2 \chi_2 + \dots + \omega_n \chi_n)}{\sum_{i=1}^n \omega_i} \quad (4)$$

Se o número de componentes selecionadas for maior ou igual a 4, a divisão fica estabelecida de forma que a componente que obteve o menor EPMd receba peso 35, a componente com o segundo menor EPMd receba peso 25, a terceira receba 20 e as demais recebam peso 20, o qual é dividido uniformemente entre elas.

A terceira forma de se criar um combinador foi obtida através da utilização de uma RNA do tipo *Multi Layer Perceptron*. Para o treinamento da rede, foram utilizados os resultados das previsões realizadas nos dias da semana de validação.

Para um melhor entendimento desta última, considere uma previsão para o dia 25/08/2002 (domingo). Este evento acontece da seguinte forma: para o treinamento da rede, são utilizados os valores de carga previstos pelas componentes selecionadas no dia 18, em um horário específico. As entradas de teste da rede são os valores previstos pelas mesmas componentes, considerando o mesmo horário, no dia 25. Como saída desejada deste treinamento, utiliza-se o valor real de carga do dia requerido que, no caso, é o próprio dia 25. O valor resultante é o valor combinado do processo para um horário específico. Seguindo este raciocínio, o processo é feito para todas às 24 horas do dia.

Neste sentido, o treinamento das componentes é uma etapa que merece certo cuidado nas escolhas das entradas, pois as saídas de previsão serão de certa forma, mapeadas através das entradas que alimentam estas componentes.

A seleção das componentes está totalmente vinculada ao processo de melhoria da previsão, por ser considerada um evento que elimina aquelas componentes cujo EPMd não atenda a uma precisão pré-estabelecida. Conforme já apresentado, a partir da variação aleatória dos parâmetros dos modelos considerados, foram geradas 2000 componentes de previsão. As componentes que alcançaram os menores índices de erro percentual médio diário na semana de validação foram selecionadas para compor a combinação para prever a semana de teste.

Esta seleção foi feita de seguinte forma: a componente que obteve o menor EPMd, dentre as demais, para um determinado dia, é escolhida juntamente com aquelas que obtiveram um EPMd de até 5% acima do EPMd da componente primeiramente escolhida. Este valor de 5 % foi escolhido com base em testes realizados de forma empírica, cujo comportamento apresentado se mostrou coerente e considerável.

A Figura 3 aborda esta ideia, de uma forma mais abrangente, apresentando os modelos de previsão, a variação dos parâmetros de cada um, as componentes geradas e a escolha destas para compor o combinador.




Figura 3 – Esquema de organização da previsão, apresentando os modelos e as componentes geradas.

Fonte: Autoria própria (2011)

5. Resultados das Componentes individuais

Nesta seção são apresentados os resultados de previsão das componentes que foram selecionadas para compor os combinadores. Esta seleção obedece aos critérios anteriormente discutidos. Portanto, ao observar os dias de previsão, na Tabela 1, percebe-se que a maioria das

componentes que alcançaram numericamente os menores índices de erros foram aquelas obtidas através da variação dos parâmetros da rede neural artificial.

A Tabela 1 foi estruturada de forma que o número de identificação da componente e o modelo da mesma são mostrados na primeira e segunda coluna, respectivamente; o dia de validação e o EPMd correspondente na terceira e quarta colunas, respectivamente; o dia de previsão e o EPMd associado na quinta e sexta colunas, respectivamente. Para cada dia, o EPMd da semana de validação é apresentado em ordem crescente. Portanto, fica fácil identificar, dentre as componentes selecionadas, o EPMd da melhor componente. A ordenação numérica aparece na primeira coluna. Os erros numericamente menores de cada dia da semana são destacados em amarelo na última coluna.

A Tabela 1 contempla as componentes selecionadas na semana de validação, juntamente com seus resultados para esta semana e a previsão para os dias na semana de teste. Esta previsão ficou caracterizada pelo fato de que nenhuma das componentes selecionadas que obtiveram o melhor desempenho no dia de teste, alcançaram um EPMd numericamente menor que a melhor componente verificada no dia de validação.

A combinação de resultados de previsão é sugerida acreditando-se que os erros de um previsor sejam compensados pelos erros de outros previsores. Contudo, existe a possibilidade de ocorrer cenários em que a discrepância entre estes resultados para o dia de teste é relevante, o que acaba comprometendo a combinação.

A partir da análise da Tabela 1, é possível perceber que nem sempre as melhores componentes selecionadas para o dia de validação se comportam da mesma forma para o dia de teste. Para exemplificar, ao observar o dia 27 (Terça), a componente que alcançou o melhor resultado de previsão no dia de validação não alcançou o melhor resultado no dia de teste, ou seja, o EPMd da componente 01 foi inferior ao da componente 04, ficando a primeira componente com o valor do EPMd igual a 2,44% e a segunda componente com o valor do EPMd igual a 2,29%. Ao observar o dia 20 (Terça), rotulado como de validação, a componente 01 obteve o EPMd com valor igual a 0,64% e a componente 04 obteve o EPMd com valor igual a 0,67%.

Vale destacar que, eventualmente pode acontecer da pior componente selecionada no dia de validação alcançar o melhor desempenho no dia de teste, conforme ocorrido no dia 26 (Segunda), da Tabela 1. Porém, este desempenho não resultou em um EPMd numericamente menor que o EPMd da melhor componente do dia de validação. No dia 19 (validação), o valor do EPMd da melhor componente foi de 0,97% contra 2,12% da melhor componente no dia 26 (teste).

Tabela 2 – Erro Percentual Médio Diário Verificado para as Componentes Seleccionadas

Id	Modelo da Componente	Dia Validação	EPMd	Dia Teste	EPMd
01	RNA	18 (Dom)	1,12%	25 (Dom)	2,10%
02	RNA		1,14%		2,71%
03	RNA		1,14%		1,77%
04	RNA		1,15%		1,85%
05	RNA		1,15%		1,79%
06	RNA		1,16%		1,75%
07	RNA		1,16%		1,69%
08	RNA		1,17%		1,83%
09	RNA		1,18%		1,92%
01	RNA	19 (Seg)	0,97%	26 (Seg)	2,23%
02	RNA		1,00%		2,27%
03	RNA		1,01%		2,35%
04	RNA		1,01%		2,17%
05	RNA		1,01%		2,18%
06	RNA		1,02%		2,44%
07	RNA		1,02%		2,20%
08	RNA		1,02%		2,12%
01	RNA	20 (Ter)	0,64%	27 (Ter)	2,44%
02	RNA		0,64%		2,33%
03	RNA		0,65%		2,42%
04	RNA		0,67%		2,29%
05	RNA		0,67%		2,41%
06	RNA		0,67%		2,41%
01	RLM	21 (Qua)	0,82%	28 (Qua)	1,41%
01	RLM	22	0,99%	29	1,76%
02	RNA	(Qui)	1,045	(Qui)	1,63%
01	RLM	23 (Sex)	0,64%	30 (Sex)	1,19%
01	PG	24 (Sab)	1,42%	31 (Sab)	2,84%
02	PG		1,44%		2,91%
03	PG		1,45%		2,62%
04	PG		1,46%		2,70%

Fonte: Autoria Própria (2011)

Diante desta ótica, é possível perceber que a seleção das melhores componentes no dia de validação nem sempre garantem uma boa previsão no dia de teste. Isto se dá pelo fato da previsão de carga elétrica se enquadrar em um processo estocástico. Porém, isto não se torna um fator capaz de desmotivar ou ameaçar a empregabilidade de uma previsão combinada.

Um acontecimento considerado ideal e desejável seria que os erros obtidos pelas componentes selecionadas fossem numericamente menores ou iguais aos erros de previsão alcançados na semana de validação, por essas mesmas componentes. De uma forma geral, as componentes selecionadas conseguiram alcançar um desempenho interessante nos dias de teste. A próxima subseção detalha o resultado da previsão combinada.

6. Resultados do Combinadores

Avaliando a Tabela 2, verifica-se que, para cada dia da semana, um combinador pode ser mais eficiente que os outros combinadores ou, até mesmo, nenhum deles se sobressair, perdendo algum desempenho, em termos de precisão no resultado, para as componentes individuais.

A organização da Tabela 2 se deu de forma que foram abrangidos os valores do EPMd dos previsores combinados, permitindo uma análise mais facilitada dos resultados. As colunas representam os dias de previsão de cada semana e as linhas abordam os combinadores, a melhor componente individual e a pior componente individual. O valor do EPMd considerado numericamente menor, para cada dia, é destacado. Os dias em que não são percebidos os destaques na tabela referem-se àqueles cujos valores do EPMd empatam com a melhor componente individual. Este empate ocorre pelo fato de apenas uma componente ter sido selecionada no dia de validação. Esta situação ocorre nos dia 30 (Sexta) da Tabela 2, por exemplo.

A Tabela 2 é caracterizada por apresentar certa diversidade em termos de desempenho dos elementos envolvidos. O dia 28 (Quarta) merece destaque nesta semana, uma vez que apenas uma componente individual foi selecionada no dia de validação e a rede neural artificial conseguiu mapear, com 0,9% a mais de precisão, o resultado combinado. Portanto, os valores do EPMd, observados nos dias 25 (domingo) e 28 (quarta) evidenciam que a RNA obteve sucesso na precisão do resultado quando comparada com a melhor componente individual verificada, para estes dois dias.

Contrariando o ocorrido no dia 28, a rede neural perdeu certa precisão nos resultados para o dia 30 (Sexta), em que apenas um componente de previsão fora selecionada. Uma situação também interessante, a qual marcou o dia 29 (Quinta), foi o empate entre os valores do EPMd dos combinadores identificados pela média aritmética e média ponderada, tendo acontecido, possivelmente pelo ajuste de pesos da média ponderada.

É interessante comentar ainda, observando a Tabela 2, que a média ponderada obteve valores idênticos ou bem próximos à média aritmética, porém com valores menos precisos. Este acontecimento possivelmente está relacionado ao ajuste de pesos, que prioriza o resultado da melhor componente individual, escolhida na semana de validação, o que não necessariamente garante que esta componente se comporte da mesma forma quando aplicada na semana de teste.

Tabela 2 – Erro Percentual Médio Diário Verificado para os Combinadores

	Dia 25 (Dom)	Dia 26 (Seg)	Dia 27 (Ter)	Dia 28 (Qua)	Dia 29 (Qui)	Dia 30 (Sex)	Dia 31 (Sab)
MA	1,80%	2,22%	2,38%	1,41%	1,43%	1,19%	2,69%
MP	1,86%	2,25%	2,39%	1,41%	1,43%	1,19%	2,71%
RNA	1,54%	2,21%	2,36%	0,42%	1,45%	1,39%	3,69%
Melhor Comp.	1,69%	2,12%	2,29%	1,41%	1,63%	1,19%	2,62%
Pior Comp.	2,10%	2,44%	2,44%	1,41%	1,76%	1,19%	2,91%

Fonte: Autoria Própria (2011)

Analizando os dias 26 (Segunda), 27 (Terça) e 31 (Sábado), é possível notar que os combinadores que alcançaram os resultados que mais se aproximam dos valores do EPMd da melhor componente individual são a rede neural para os dias 26 e 27 e a média aritmética para o dia 31. Contudo, é possível perceber que, quando a precisão dos resultados dos combinadores é inferior à precisão do resultado da melhor componente individual, pelo menos um dos combinadores alcança um valor bem próximo ao obtido pela componente individual.

Partindo desta análise, foi possível verificar que os combinadores, de uma forma geral, possuem uma boa capacidade de generalização, aumentando a acurácia dos resultados, em grande parte das situações. Nas situações em que o desempenho do combinador não supera o desempenho da melhor componente individual, os resultados muito se aproximam, com uma distância mínima entre eles. Portanto, existe certa motivação em se aplicar a combinação dos resultados com a finalidade de otimizar a previsão de carga elétrica.

7. Conclusões

O cenário de previsão de séries temporais é considerado um campo em que a pesquisa atua de forma constante, diversas ferramentas são elaboradas visando atender aos mais diversos tipos de séries que existem. Contudo, não existe uma metodologia específica, que é a melhor em todos os casos. Neste sentido, a previsão de séries temporais de carga elétrica é uma tarefa não trivial, na qual está envolvida uma infinidade de variáveis. Desta forma, um previsor especialista tende a registrar altos níveis de erros de previsão ao longo do tempo.

As previsões efetuadas neste trabalho procuraram demonstrar a eficácia de um combinador, cuja técnica tende a ser robusta e a apresentar desempenho capaz de suavizar os erros e otimizar os resultados. Este processo se mostra importante pelo fato de que o acompanhamento da carga é uma das exigências básicas nos processos de operação e controle em um sistema de potência.

As análises realizadas demonstraram que os resultados das componentes individuais de previsão, quando submetidos a um determinado tipo de combinação, se comportam de maneira semelhante ou superior a melhor componente individual, em boa parte dos dias considerados na semana de teste, e superando a pior componente individual para todos os casos. A técnica utilizada envolveu os seguintes modelos: Redes Neurais Artificiais, Programação Genética e Regressão Linear Múltipla. Neste sentido, a aplicação da abordagem proposta pode se tornar viável e interessante em cenários semelhantes, em que a precisão na previsão dos resultados é requerida.

Portanto, a utilização de um combinador de previsão em substituição à utilização de apenas uma componente, tratada de forma individual, pode ser considerada válida e eficaz, levando em conta a capacidade de generalização do mesmo.

Referências

- DRAPER, N.R. E SMITH, H. **Applied Regression Analysis**. John Wiley & Sons, pp. 70-136, 1981.
- DREZGA, I. E RAHMAN, S. Short-Term Load Forecasting, **IEEE Transactions On Power Systems**, Vol, 14, No, 3. 1999.
- HANSEN, L. K. E SALAMON, P. **Neural network ensembles**, IEEE Trans - Pattern Anal, Machine Intell, PAMI-12, 10, pp, 993-1001. 1990.
- HAYKIN, S, **Neural Networks**, A Comprehensive Foundation, Macmillan Publishing Company, 1994.
- KOZA, J. R. **Genetic Programming: On the Programming of Computers by Means of Natural Selection**, MIT Press, 1992.
- LEONE FILHO, M. A., OHISHI, T. E BALLINI, R. Ensembles of Selected and Evolved Predictors using Genetic Algorithms for Time Series Prediction, **IEEE World Congress on Computational Intelligence**, Vancouver, 2006.
- LI, Y., WANG, D. F. E HAN, P. **Selective Ensemble Using Discrete Differential Evolution Algorithm For Short-Term Load Forecasting**, Eighth International Conference On Machine Learning And Cybernetics, Baoding, 2009.
- SALGADO, R. M., PEREIRA, J. J. F., OHISHI, T., BALLINI, R., LIMA, C. A. M., E VON ZUBEN, F. J. A Hybrid Ensemble Model Applied to the Short-Term Load Forecasting Problem, **Wcci-Ieee World Congress On Computational Intelligence**, Vancouver – Canadá, 2006.
- SAPELUK, A. T., OZVEREN, C. S. E BIRCH, A. P. **Short Term Electric Load Forecast Using Artificial Neural Networks**, Electrotechnical Conference, 905 - 908 Vol.3, IEEE. 1994.
- SIWEK K. E OSOWSKI, S. **Short Term Load Forecasting Model In The Power System Using Ensemble Of Predictors**, Instrumentation And Measurement Technology Conference - Imtc 2007 Warsaw, Poland, 2007.